

# Bacharelado em Ciência da Computação

## *Processamento de Imagens*

### Wavelets Unidimensionais

# Conceitos básicos

- Pode-se projetar *wavelets* otimizadas para realizar análises especiais, em que as *wavelets* tenham características semelhantes aos sinais sob análise: uma espécie de Homeopatia Matemática - a cura pelos semelhantes.
- *Wavelets* que são utilizadas para compressão de dados, podem ser péssimas para aplicações de análises de sinais biológicos, ou síntese de música. Da mesma forma, *wavelets* para síntese de sons podem não ser úteis em aplicações para compressão de dados.
- *Wavelets* podem ter caráter fractal e terem padrões que se repetem em escalas diferentes.

# Histórico

- Em 1909, a primeira menção: tese de doutorado de **Alfred Haar**, análise escalonada.
  - As Wavelets de Haar, embora de suporte compacto não são continuamente diferenciáveis.
- Década de 80, **Alex Grossmann** (*Université de Marseille*) e **Jean P. Morlet** (*Elf Aquitaine*) introduziram o conceito de *wavelets*.
  - Morlet recebeu o prêmio *Reginald Fessenden Award 1997*.
- Em 1985, **Stéphane Mallat** (França) estabeleceu a ligação desta teoria com o processamento digital de sinais.
- **Yves Meyer** (França) construiu uma das primeiras *wavelets* não triviais, continuamente diferenciáveis.
- **Ingrid Daubechies** (Bélgica) construiu o mais usado conjunto de *wavelets* ortogonais de suporte compacto (tempo-limitada).

## *Por que wavelets?*

Em que esta ferramenta pode ser mais potente que a análise espectral clássica de Fourier?

*De onde surgiram as wavelets?*



# Análise Espectral para Sinais Não Estacionários

- Os sinais devem ser tratados não no domínio  $t$  ou domínio  $f$ , mas em ambos (espaço conjunto tempo-frequência)!
- Há vantagens no uso da análise *wavelet* ao invés da análise de Fourier, por exemplo, em situações em que os sinais contém descontinuidades e/ou variações abruptas e curtas.
- Uma das características centrais é ser bem adaptada a sinais de curta duração e com variações muito rápidas, tais como sinais transitórios, sísmicos, de voz, etc.

# Conceito de Estacionaridade

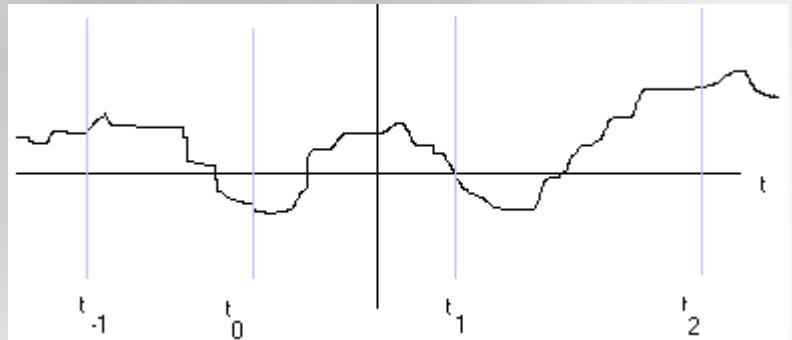


Ilustração de um trecho de um sinal (possivelmente) estacionário.

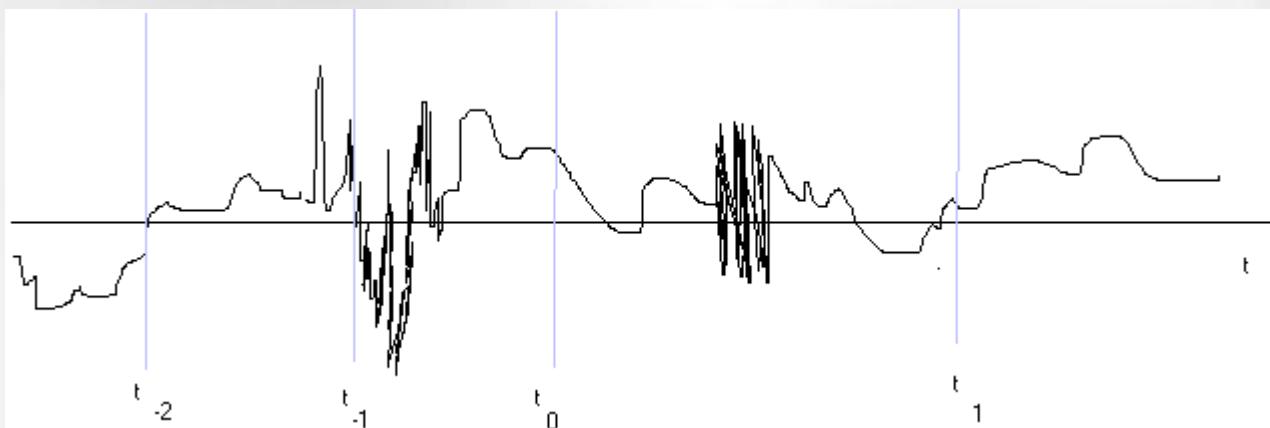


Ilustração de um trecho de um possível sinal não estacionário.

- A Transformada de Fourier analisa a contribuição de cada componente harmônica no sinal como um todo.

# Conceito de Estacionaridade (cont.)

- O sinal estacionário apresenta um comportamento "mais ou menos" semelhante em qualquer trecho analisado.
- Abordagem pouco formal, mas suficiente.
- Primeiro passo na direção das *wavelets*: a introdução de um caráter local, que tem relação com o parâmetro  $b$ , deslocamento.
- Tudo se passa como se o sinal fosse "fatiado" em vários trechos, e em cada trecho, a contribuição espectral fosse analisada, resultando em um espectro local.

# **Conceito de Estacionaridade (cont.)**

- 💡 Agora tem-se uma sequência de "fotos" do espectro

$$\dots F(w, t-1), F(w, t0), F(w, t1), F(w, t2) \dots$$

evoluindo temporalmente.

- 💡 Sinais práticos "bem comportados" com relação à estacionaridade: sinais periódicos.

# Exemplo

---

- Imagine que para representar o rosto de uma pessoa dispõe-se de 6 fotos tiradas a cada 5 anos (exemplo: aos 5 anos, 10 anos, 15, 20, 25 e 30 anos).
- Com o auxílio de técnicas de processamento de imagens, procura-se obter uma única foto representativa do indivíduo, por exemplo, tomando uma "foto média".
- A maior parte das características do indivíduo são "relativamente" mantidas com o passar do tempo.
- Essa foto média representa o espectro de Fourier. Se você deseja um caráter local (no tempo), deve trabalhar com as seis fotos, o que exige maior complexidade, maior capacidade de armazenamento e processamento. Imagine armazenar um banco com fotos de 100 milhões de pessoas!!!

# Conceito de Estacionaridade (cont.)

- A classe de sinais, cujo espectro permanece relativamente independente no tempo, são referidos como sinais estacionários.
- Os não-estacionários trazem variações substanciais e significativas de padrão e comportamento, dependendo do instante de tempo considerado.
  - É como se, "de repente", no meio de uma sequência de fotos 3x4 de fotos humanas semelhantes, surgisse uma foto de algum animal completamente diferente (por exemplo, de uma girafa).

# Conceito de Estacionaridade (cont.)

## ● Diferentes níveis de estacionaridade:

- Sequência de fotos sempre de uma mesma pessoa em diferentes tempos;
- Sequência de fotos de pessoas diferentes em tempos diferentes, porém de uma mesma raça (origem);
- Sequência de fotos de pessoas diferentes em tempos diferentes, porém de origens diferentes;
- Sequência de fotos de diferentes animais em tempos diferentes (levando em conta algum aspecto da classificação);
- Sequência de fotos arbitrárias diferentes em tempos diferentes, incluindo objetos, paisagens etc.

● Quando o espectro de Fourier passa a não ter sentido?. A resposta não é fechada.

● Depende do que se deseja e quanto se pode "pagar".

# Transformada de Gabor

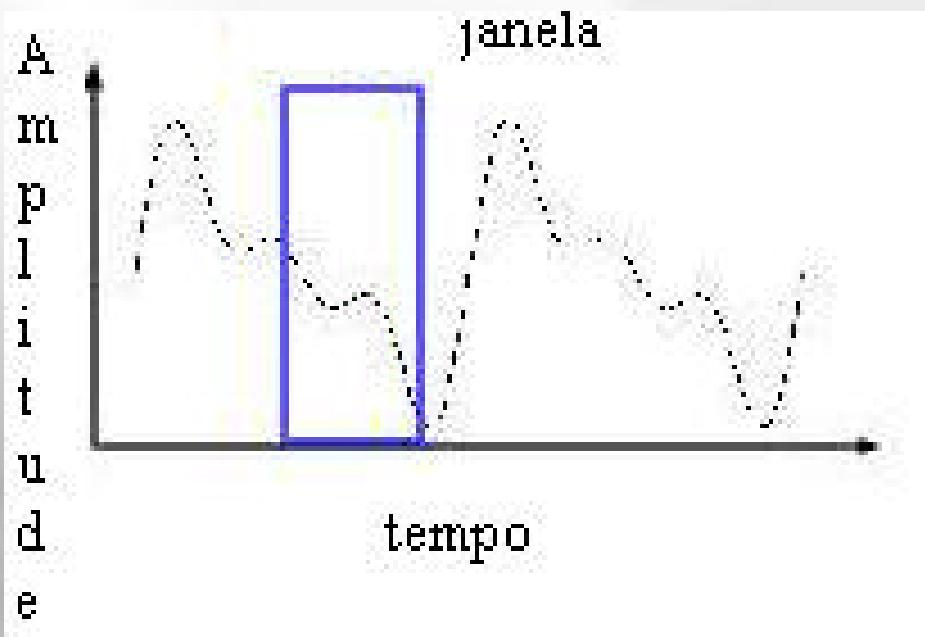
- Uma das grandes desvantagens da análise de Fourier: apresenta apenas resolução na frequência e não no tempo.
  - Embora capaz de determinar o conteúdo de frequências presentes em um sinal, não há noção de quando (em que intervalo de tempo) elas ocorrem.
- A teoria por trás da análise de Fourier diz que um sinal pode ser representado por uma soma infinita de termos em seno e cossenos, mais conhecida como a expansão de Fourier.
- Maior vantagem da Transf. de Fourier: poder determinar todas as frequências presentes no sinal.
- Desvantagem: sua relação com o domínio temporal é inexistente.
  - Não fornece uma análise temporal, apenas frequencial.

# Transformada de Gabor (cont.)

- Transformada de Fourier de Tempo Curto (STFT – *Short Time Fourier Transform*) também conhecida como a **Transformada de Gabor**.
  
- A ideia da STFT é introduzir um parâmetro de frequência local (local no tempo) como se a "Transformada de Fourier Local" observasse o sinal através de uma curta "janela" dentro da qual o sinal permanece aproximadamente estacionário.

# Transformada de Gabor (cont.)

- A transformada local observa  $f(t)$  "através" de uma janela  $W(t)$  centrada no instante de tempo  $\tau$  e de extensão "limitada", antes do cálculo do espectro.



# Transformada de Gabor (cont.)

- ◆ Formalmente,

$$STFT(w, \tau) = \int_{-\infty}^{+\infty} f(t)W^*(t - \tau)e^{-jwt} dt$$

- ◆ É necessária uma representação bidimensional  $F(w, \tau)$  do sinal  $f(t)$ , composta por características espectrais dependentes do tempo.
- ◆ Várias escolhas possíveis para a janela, mas a mais comum é a Gaussiana.

# Próximas perguntas

- Por que a STFT não é suficiente?
- O que seria mais apropriado, além de um transformada local (*wavelets* também são locais)?

# Próximas perguntas

- Por que a STFT não é suficiente?
- O que seria mais apropriado, além de um transformada local (*wavelets* também são locais)?
- A necessidade da segunda operação básica das *wavelets*, o escalonamento, também pode ser entendida neste contexto.
- Isto conduz a ideia de realizar a análise utilizando "Filtros Idênticos" e de "Banda Passante Relativa" constante.
- Especificando o formato de um deles (por exemplo, um filtro Gaussiano), todos os demais são instantaneamente especificados (são também Gaussianos).
- Assim, emerge a noção de *wavelet-mãe* - todas as outras são simplesmente versões escalonadas dela, e o fator de escala depende da frequência.

# Análise de wavelets

💡 Alternativa para abordar o plano conjunto tempo-frequência:

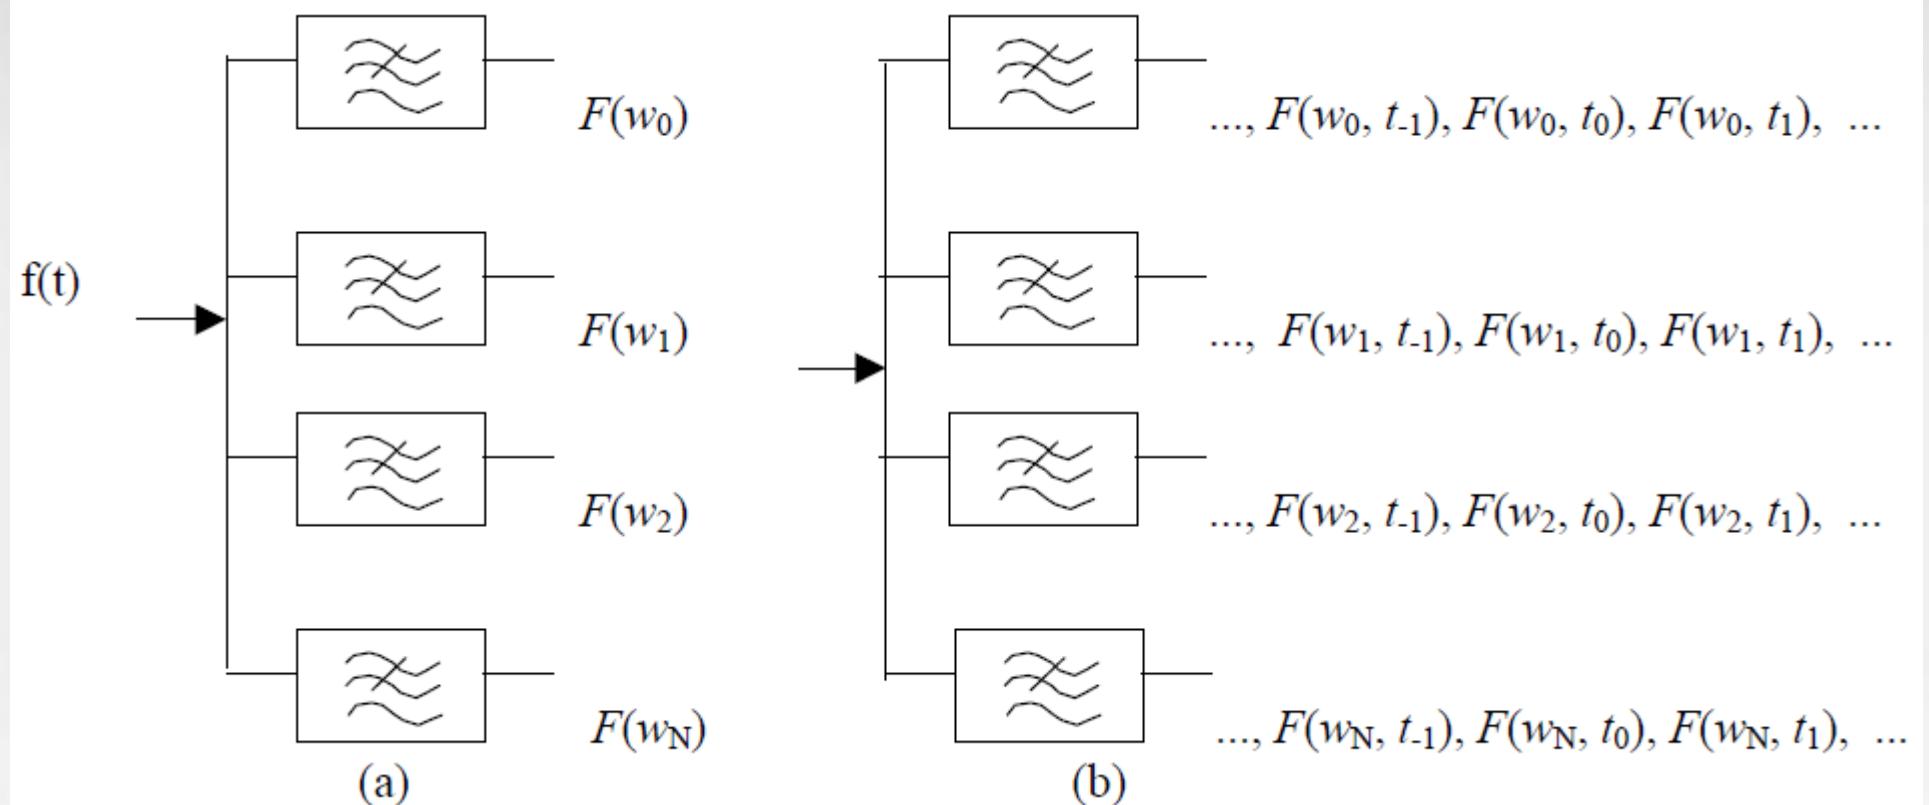
- A análise visualizada como um banco de filtros.
- Resolução no tempo deveria aumentar com o aumento da frequência central dos filtros.
- A resolução no tempo torna-se arbitrariamente boa para altas frequências, enquanto que a resolução em frequência torna-se arbitrariamente boa em baixas frequências.

## Retomando o exemplo das fotos

- Deve-se usar uma representação para um indivíduo de meia-idade com uma meia dúzia de fotos (0 ano, 5 anos, 10 anos 15 anos, 20 anos, 25 anos).
- Ao invés de tomar-se uma foto a cada 5 anos, talvez seja mais interessante considerar um conjunto de seis fotos tomadas a 1 ano, 2 anos, 4 anos, 8 anos, 16 anos e 32 anos, uma vez que nos 10 primeiros anos há mudanças mais significativas.
- Isto leva em conta que as diferenças entre as fotografias aos 20 e 25 anos são pequenas, pouco adicionando ao conhecimento.

# Análise de wavelets (cont.)

As wavelets podem ser interpretadas como as transformadas lineares locais geradas por um banco de filtros.



Análise em escala linear: (a) Fourier e (b) STFT

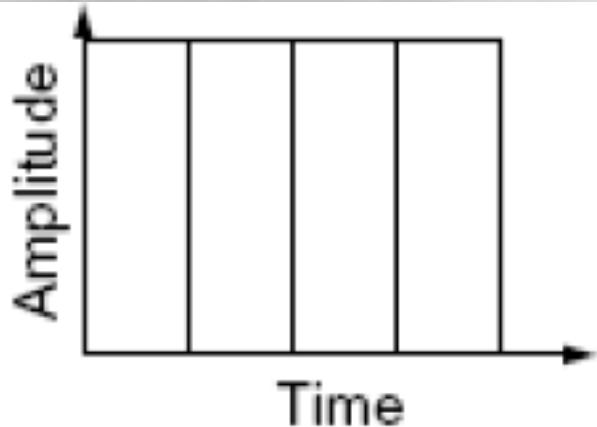
# Análise de wavelets (cont.)

- Ao invés de interpretar os parâmetros nos domínios tempo e frequência ( $f \times t$ ), costuma-se utilizar os domínios escala e deslocamento ( $a \times b$ ).
- Uma interpretação interessante está associada a lidar com imagens tipo "mapas".
- Uma mudança de escala pode permitir, numa escala maior, ter uma visão mais global, mas com menor precisão.
- Já em uma escala menor, vê-se detalhes, mas perde-se em estudar o comportamento global.

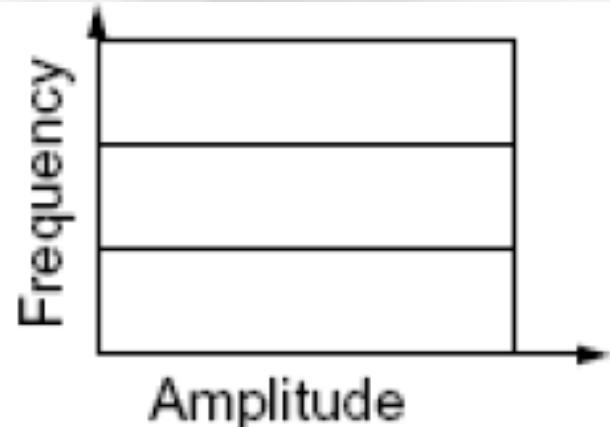
## *Exemplo: mapa do Brasil*

- O parâmetro de deslocamento permite deslocar o foco da atenção para uma outra parte do mapa.
  - Numa escala 1:15.000.000: ideia do Brasil como um todo
  - Numa escala 1:3.500.000, pode-se analisar globalmente o estado de São Paulo, perdendo-se a noção do Brasil como um todo.
- O que é melhor? Quem já usou mapas sabe que depende fundamentalmente do que se quer investigar!
- A análise via *wavelets* permite visualizar tanto a floresta quanto as árvores.

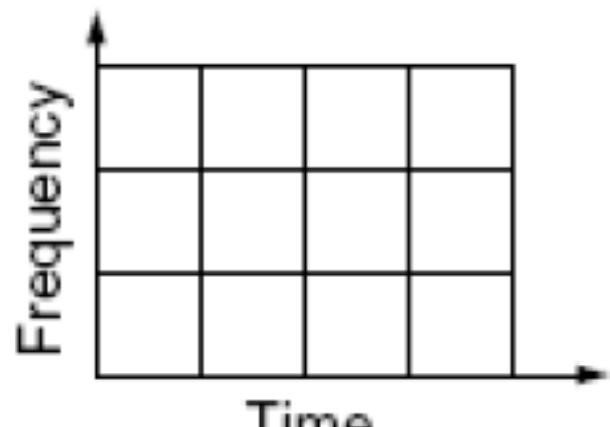
# Análise de wavelets (cont.)



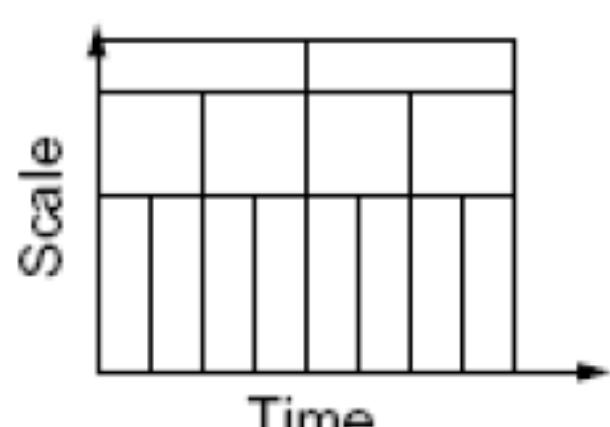
Time Domain (Shannon)



Frequency Domain (Fourier)



STFT (Gabor)



Wavelet Analysis

# Análise de wavelets (cont.)

## Objetivo da Transformada Wavelet:

- Análise local de sinais não estacionários com transitórios e informação de longa duração.
- ✓ Janelas pequenas para analisar as altas frequências.
- ✓ Janelas grandes para análise de baixas frequências.

# Análise de wavelets (cont.)

- Na **Transformada Wavelet Contínua** (CWT), todas as respostas ao impulso no banco de filtros são versões (expandidas ou comprimidas) da mesma  $\psi(t)$  chamada de **wavelet básica**.

- Transformada Wavelet Contínua:  $CWT(a, \tau) = \frac{1}{\sqrt{|a|}} \int_{-\infty}^{+\infty} f(t) \psi^* \left( \frac{t - \tau}{a} \right) dt$

$\tau \rightarrow$  parâmetro de translação (localização da *wavelet*)

$\frac{1}{\sqrt{|a|}}$   $\rightarrow$  fator de normalização da energia (todas as wavelets escaladas têm a mesma energia)

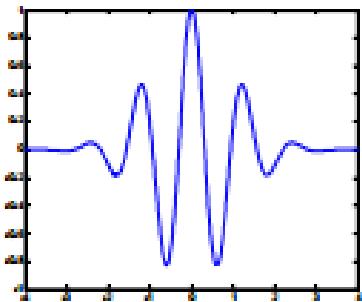
$\psi(t) \rightarrow$  *wavelet mãe*       $\psi \left( \frac{t - \tau}{a} \right) \rightarrow$  *wavelets* (funções de base)

(o \* significa conjugado complexo)

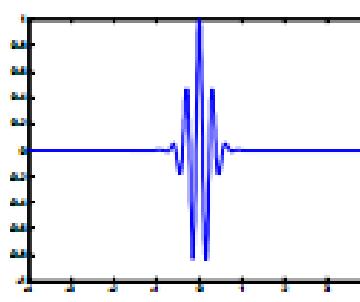
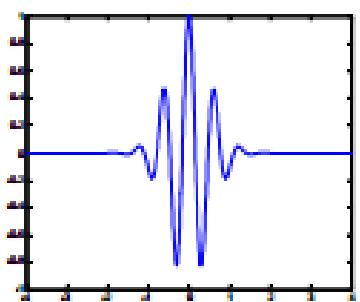
$a > 0 \rightarrow$  escala (largura) da *wavelet*

# Análise de wavelets (cont.)

$a > 1 \longrightarrow$  Wavelet dilatada



$0 < a < 1 \longrightarrow$  Wavelet contraída



# Análise de wavelets (cont.)

● A função  $\psi(t)$  é conhecida como **wavelet mãe**.

- *Wavelet mãe*: função que analisa o sinal.
- Todas as janelas são suas versões expandidas ou comprimidas (escaladas) e descoladas.

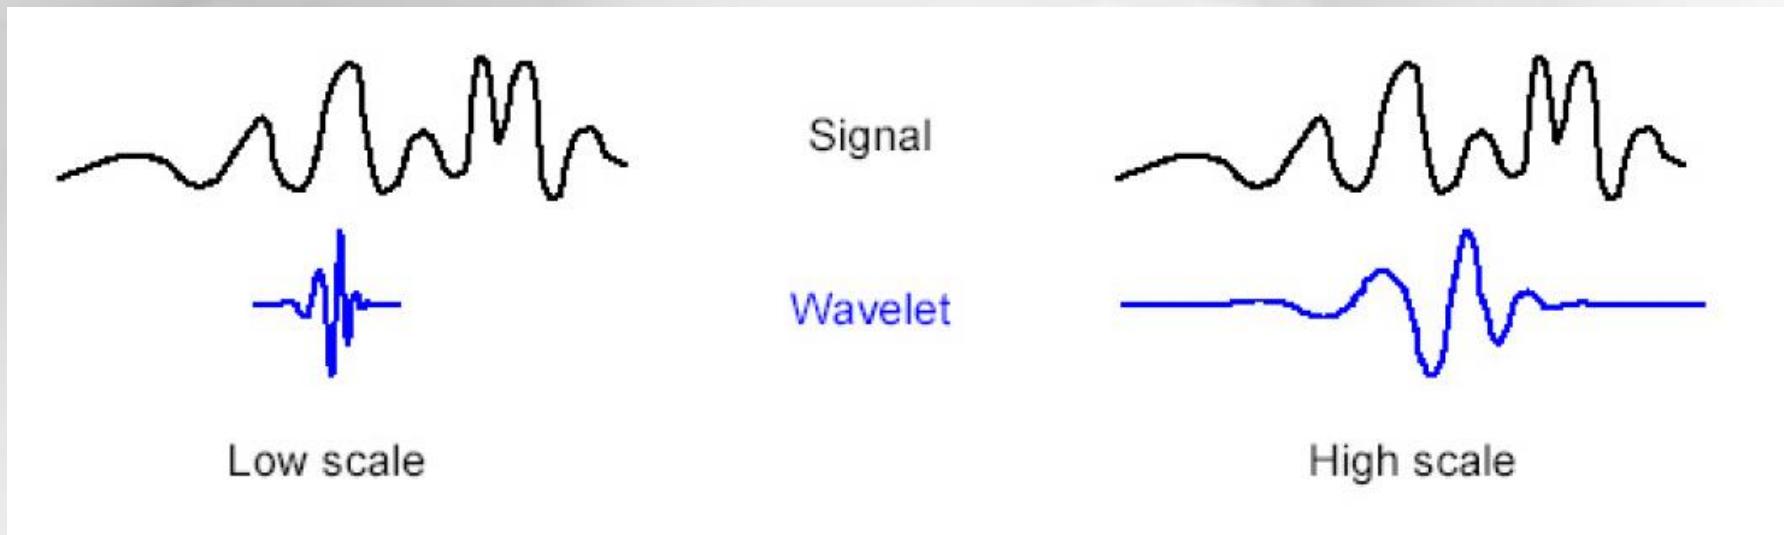
● Uma *wavelet* é uma função com média zero, ou seja:

$$\int_{-\infty}^{+\infty} \psi(t) dt = 0$$

● A partir dela geram-se versões modificações no decorrer da transformada.

● Ela é um protótipo para a geração de outras funções janela: versões dilatadas e comprimidas da mesma "wavelet mãe".

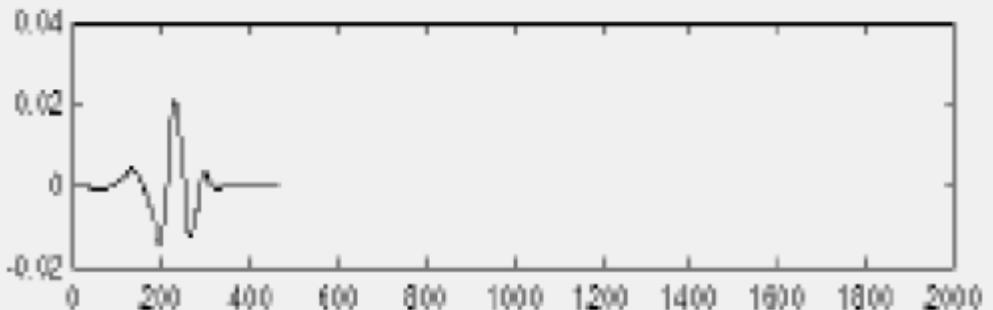
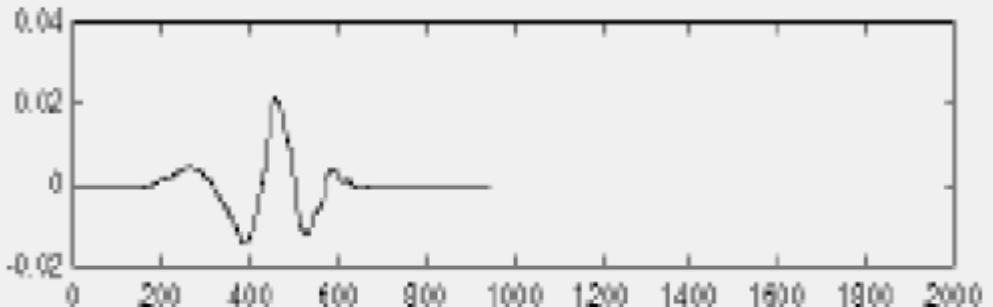
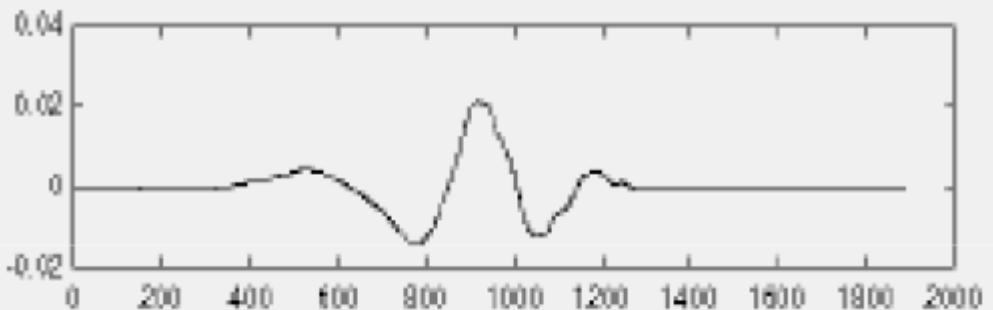
# Escala e Frequência



- Baixo valor de escala  $a \rightarrow$  wavelet comprimida  $\rightarrow$  detalhes sobre mudanças rápidas no sinal (visão detalhada do sinal)  $\rightarrow$  frequências alta.
- Alto valor de escala  $a \rightarrow$  wavelet esticada  $\rightarrow$  mudanças lentas, características grosseiras, visão global não detalhada do sinal  $\rightarrow$  frequências baixas.

# Escala e Frequência

## ● Influência da escala



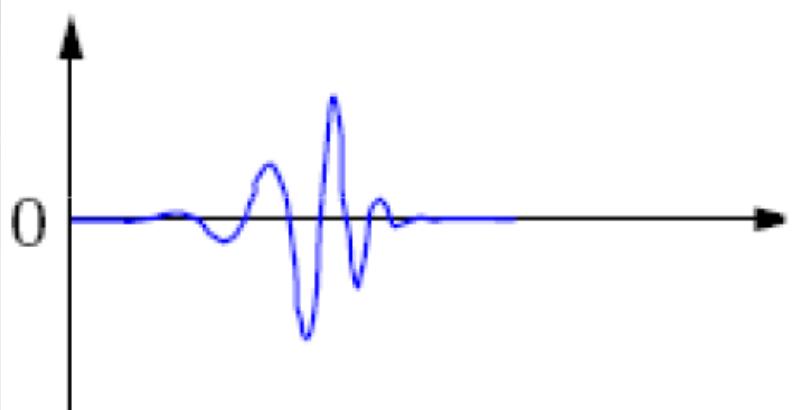
$$f(t) = \psi(t) ; \quad a = 1$$

$$f(t) = \psi(2t) ; \quad a = \frac{1}{2}$$

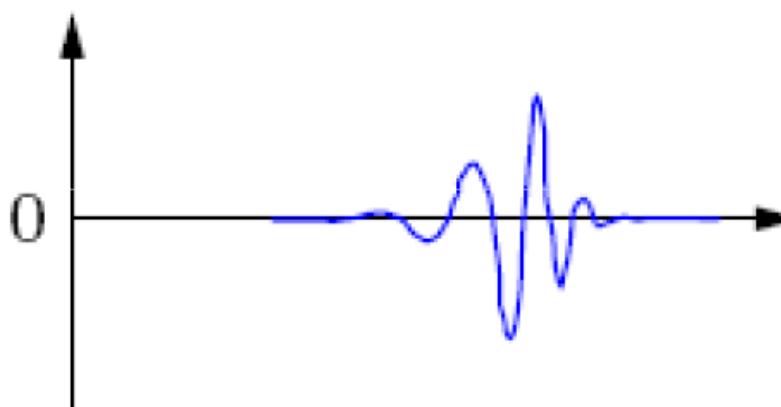
$$f(t) = \psi(4t) ; \quad a = \frac{1}{4}$$

# Escala e Frequência

## ● Influência do deslocamento

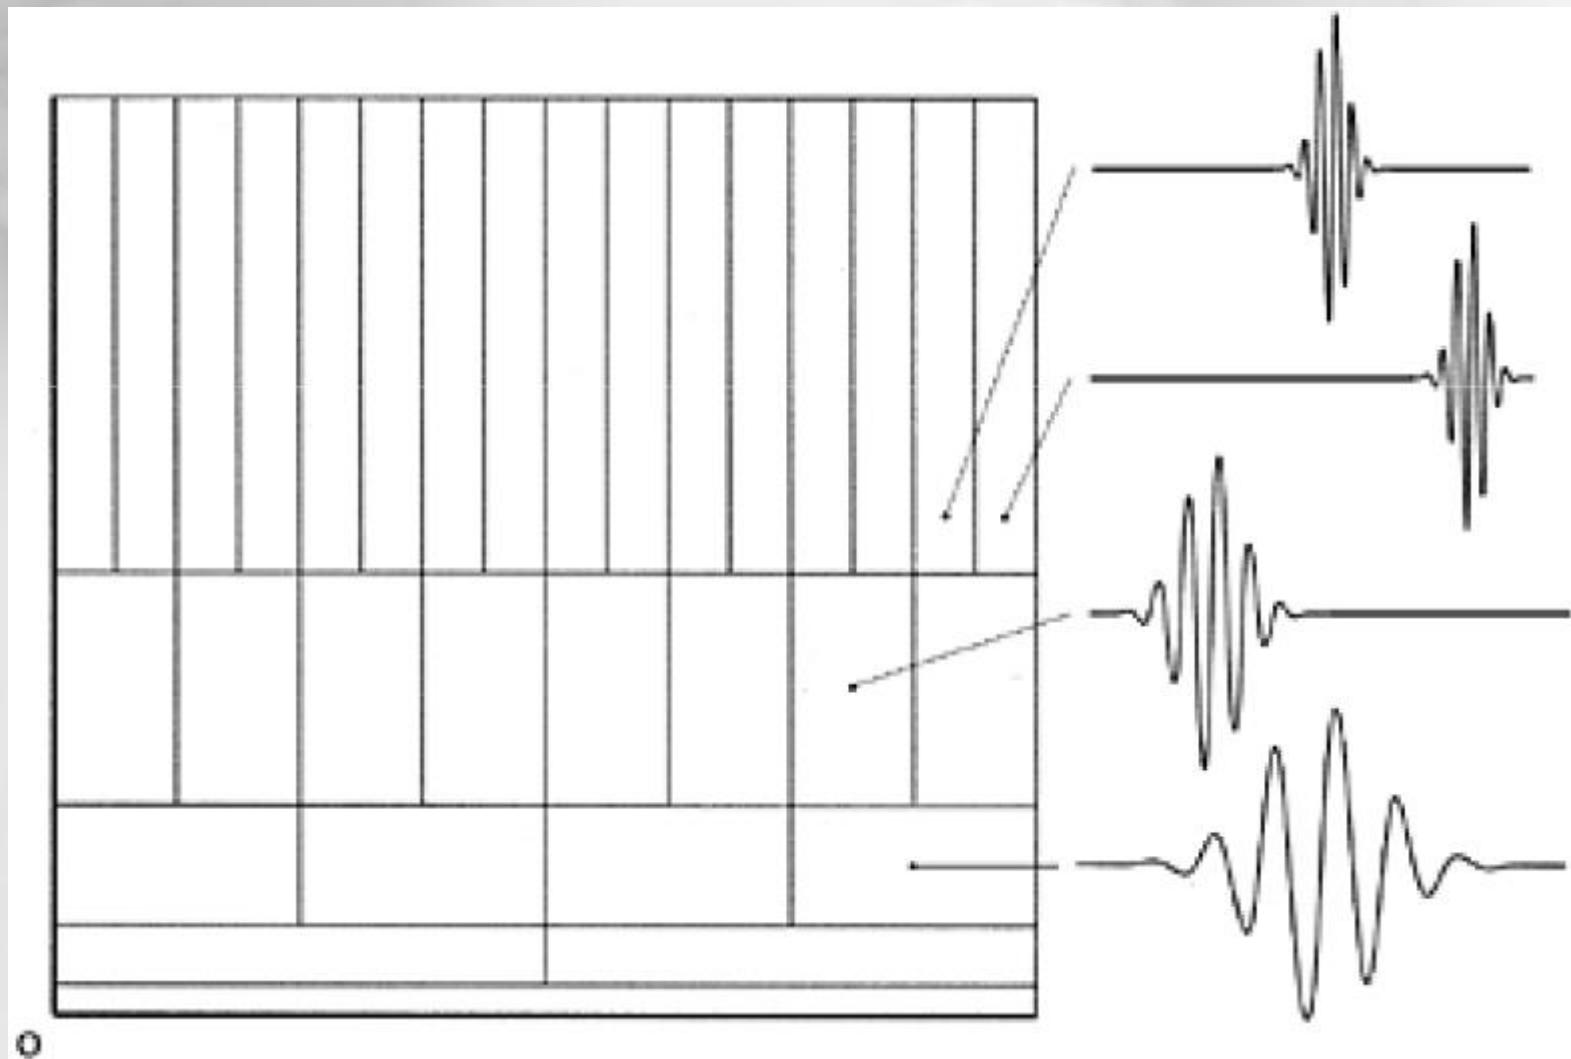


Wavelet function  
 $\psi(t)$



Shifted wavelet function  
 $\psi(t - k)$

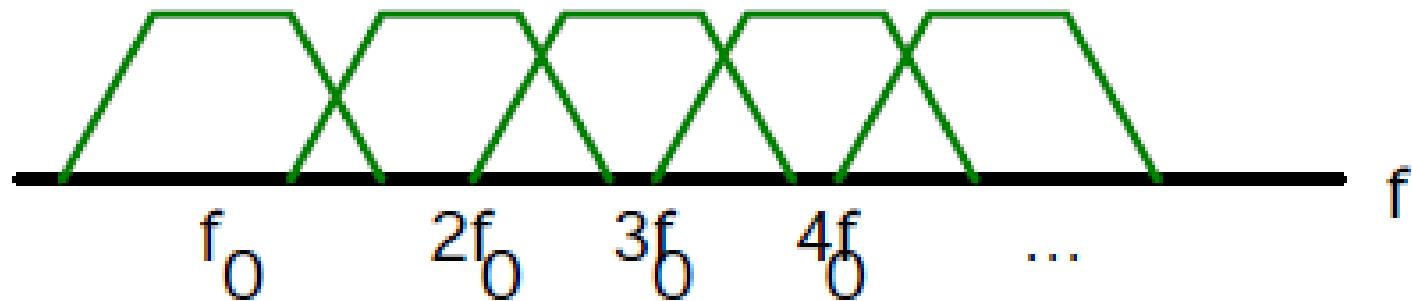
# *Escala e Frequência*



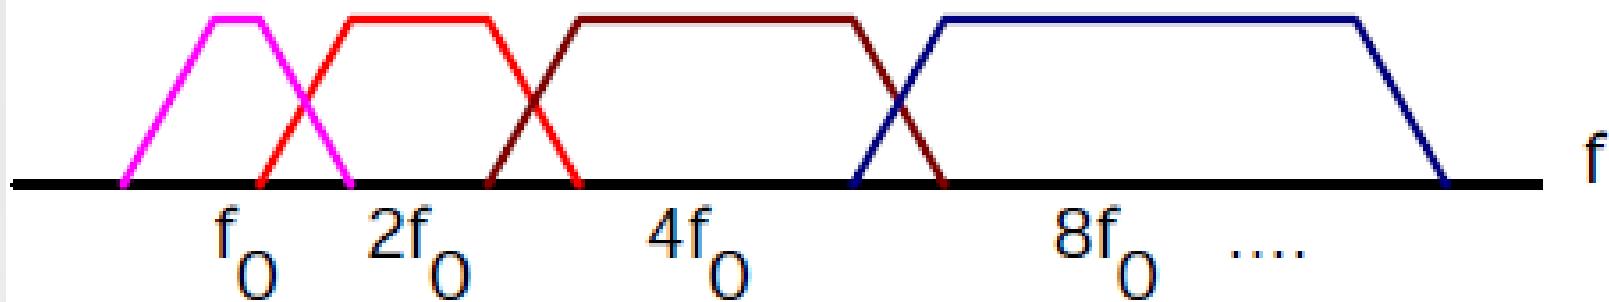
# Análise de wavelets (cont.)

Transformada localizada de Fourier utiliza janelas com dimensão fixa.

## Banda passante constante (STFT)



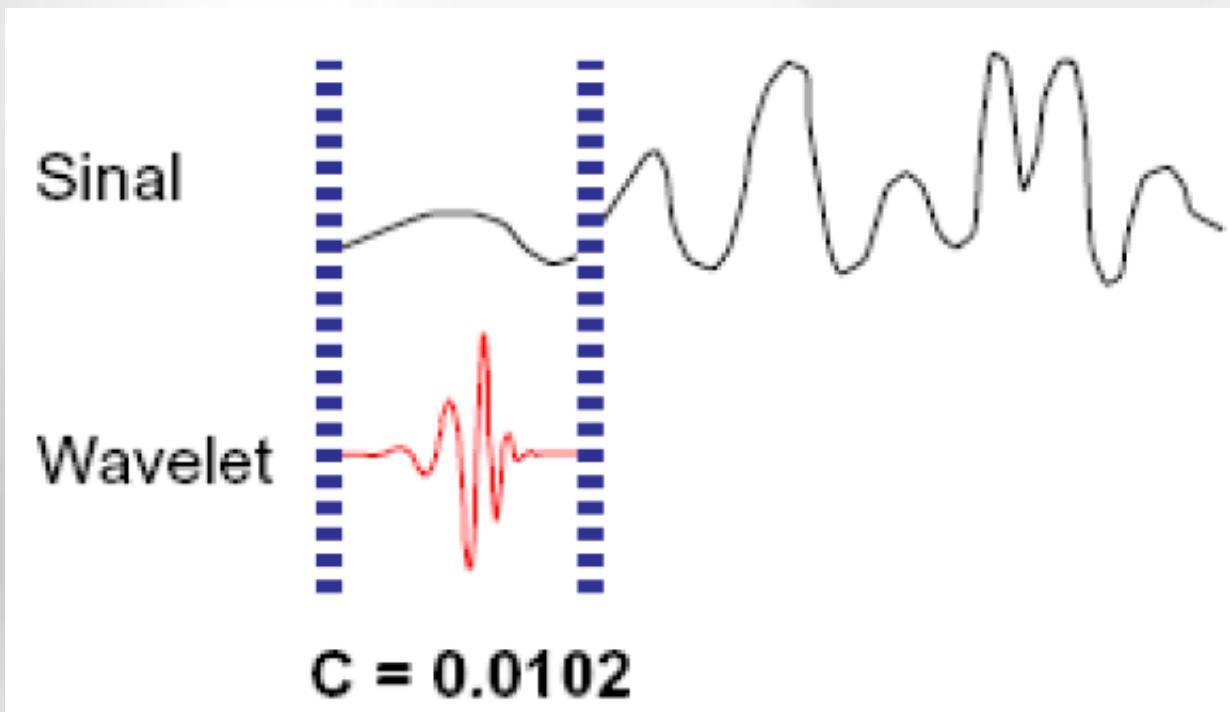
## Banda passante relativa ( $Q$ ) constante (WT)



Transformada de Wavelet utiliza janelas com dimensão variável.

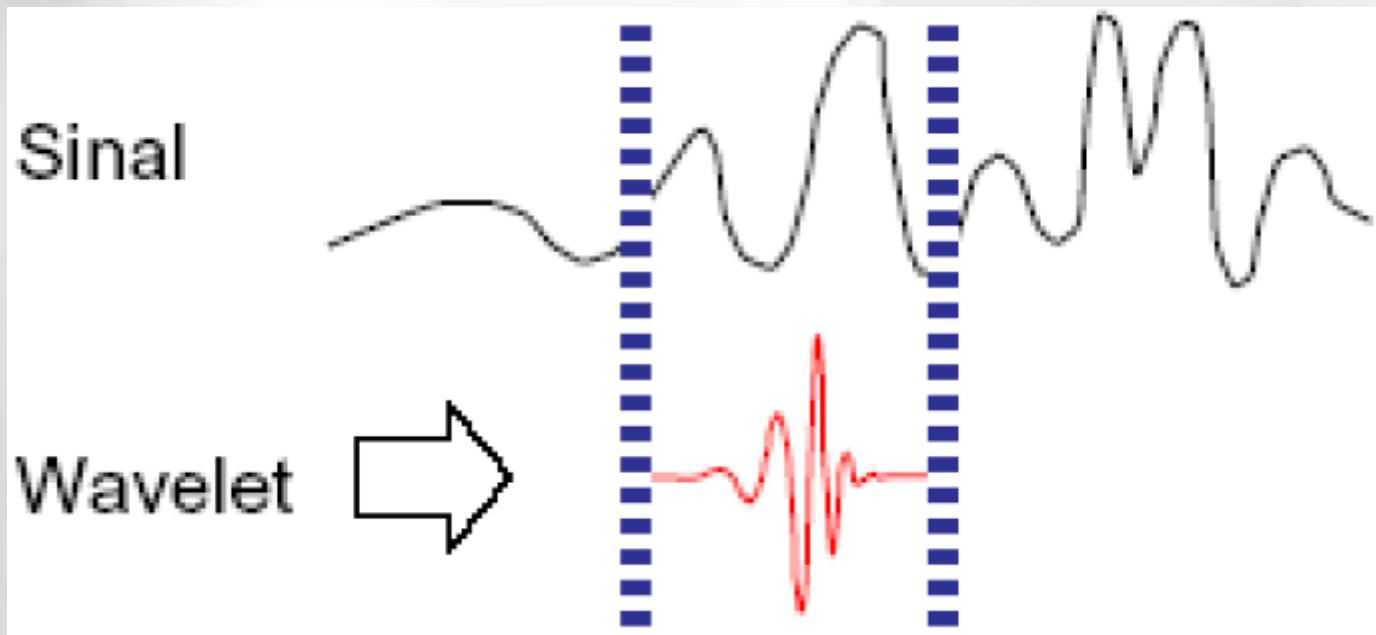
# Transformada Wavelet

1. Escolha uma *wavelet* e compare-a com uma região no início do sinal.
2. Calcule o número  $C$  que representa quão proximamente correlacionada a *wavelet* está com esta seção do sinal.



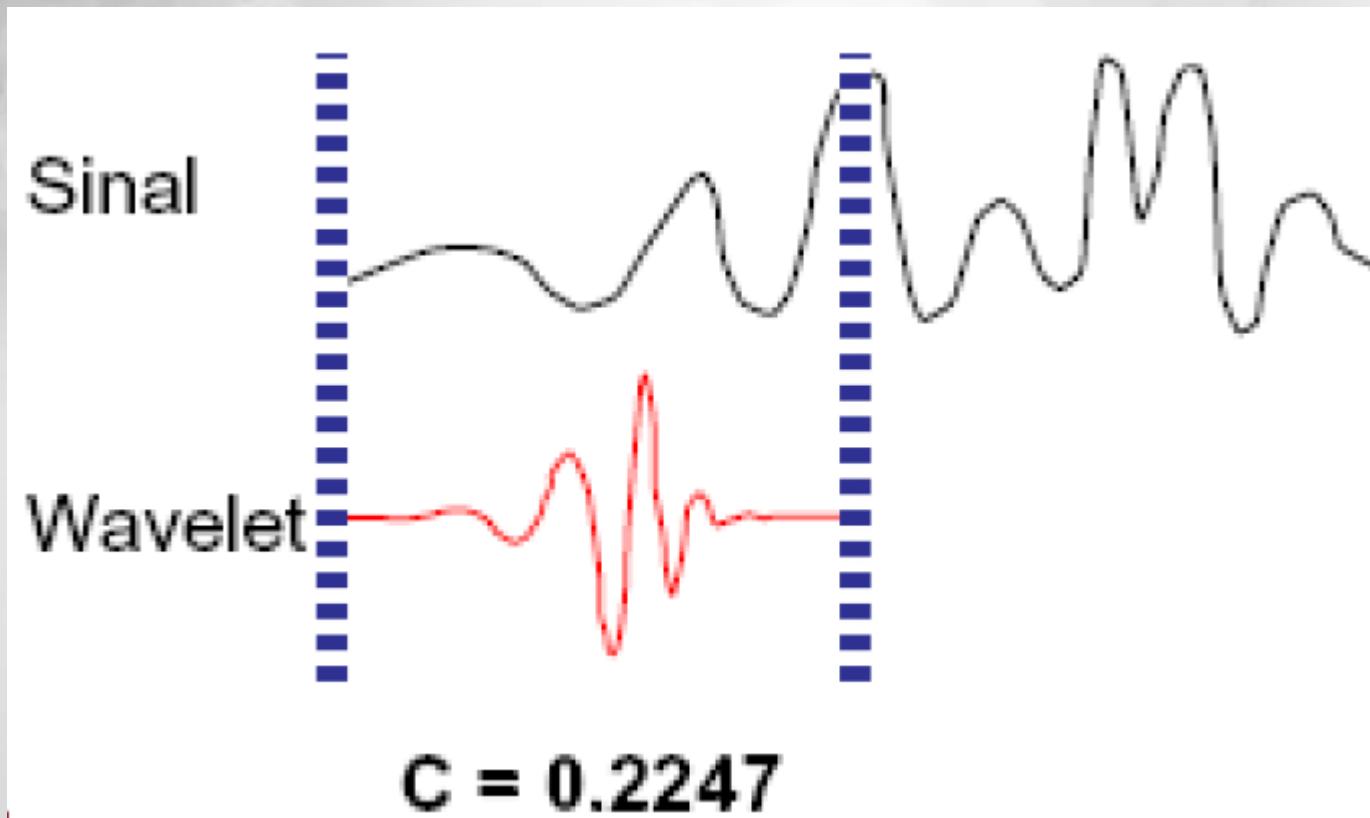
# Transformada Wavelet (cont.)

3. Desloque a *wavelet* para a direita e repita os passos 1 e 2 até que todo o sinal tenha sido coberto.



# Transformada Wavelet (cont.)

4. Escale (estique) a wavelet e repita os passos de 1 a 3



5. Repita as etapas de 1 a 4 para todas as escalas desejadas.

# Transformada Wavelet (cont.)

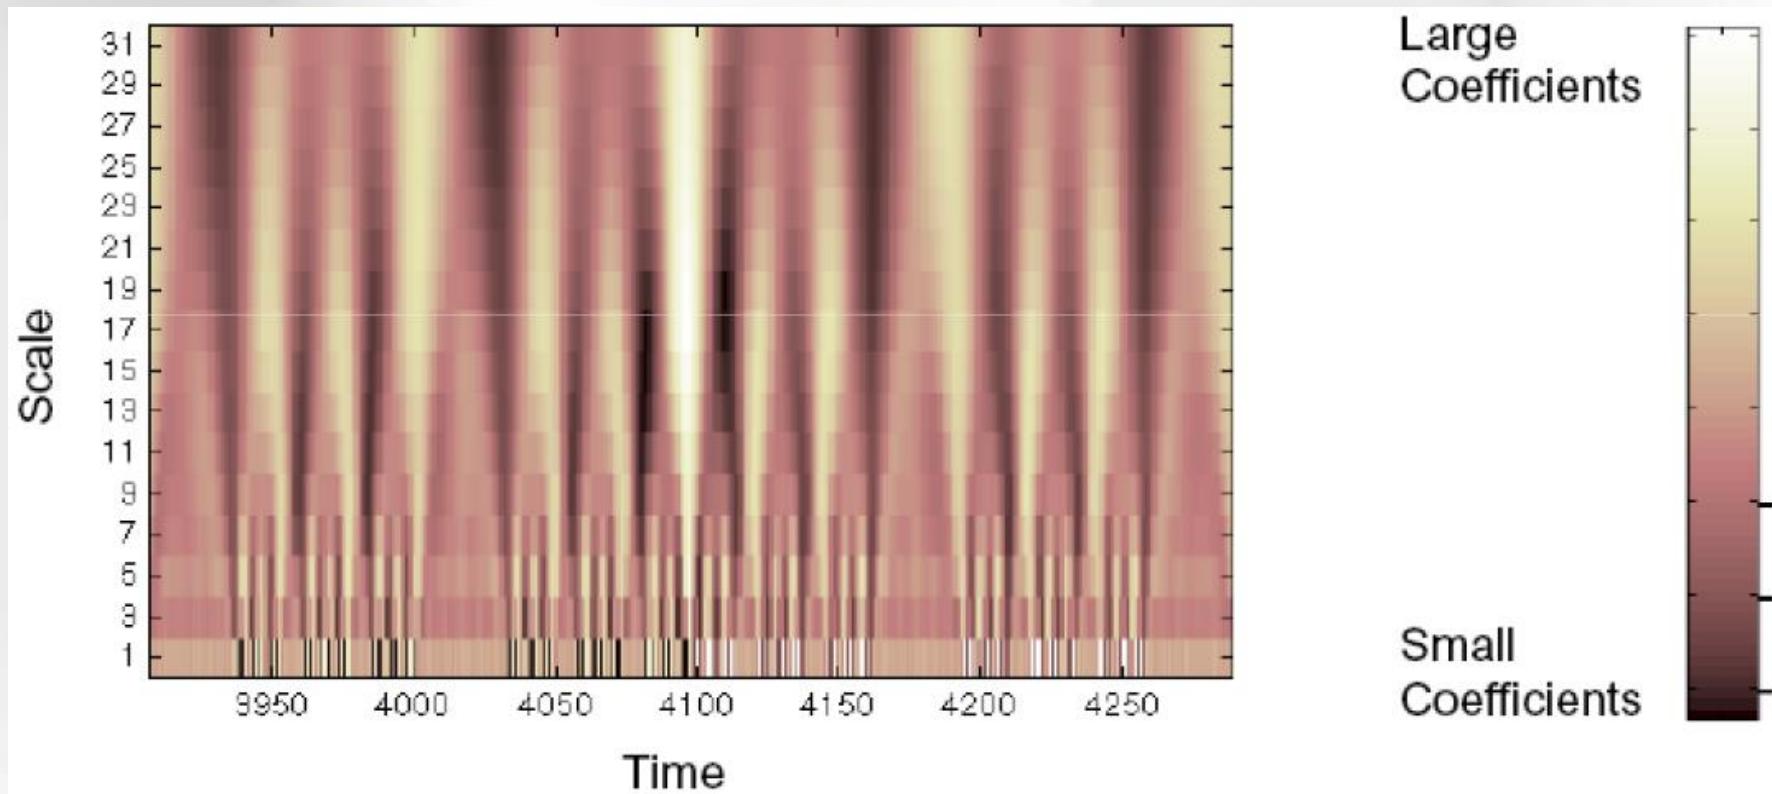
- ➊ Quando for concluído, você terá todos os coeficientes produzidos em diferentes escalas e diferentes seções do sinal.
  
- ➋ O que fazer com essas informações?

# Transformada Wavelet (cont.)

- Quando for concluído, você terá todos os coeficientes produzidos em diferentes escalas e diferentes seções do sinal.
- O que fazer com essas informações?
- Podemos avaliar qual escala de *wavelet* apresenta maior coeficiente de correlação para cada parte do sinal indicando qual a melhor escala a ser utilizada para avaliar as frequências em cada parte do sinal.

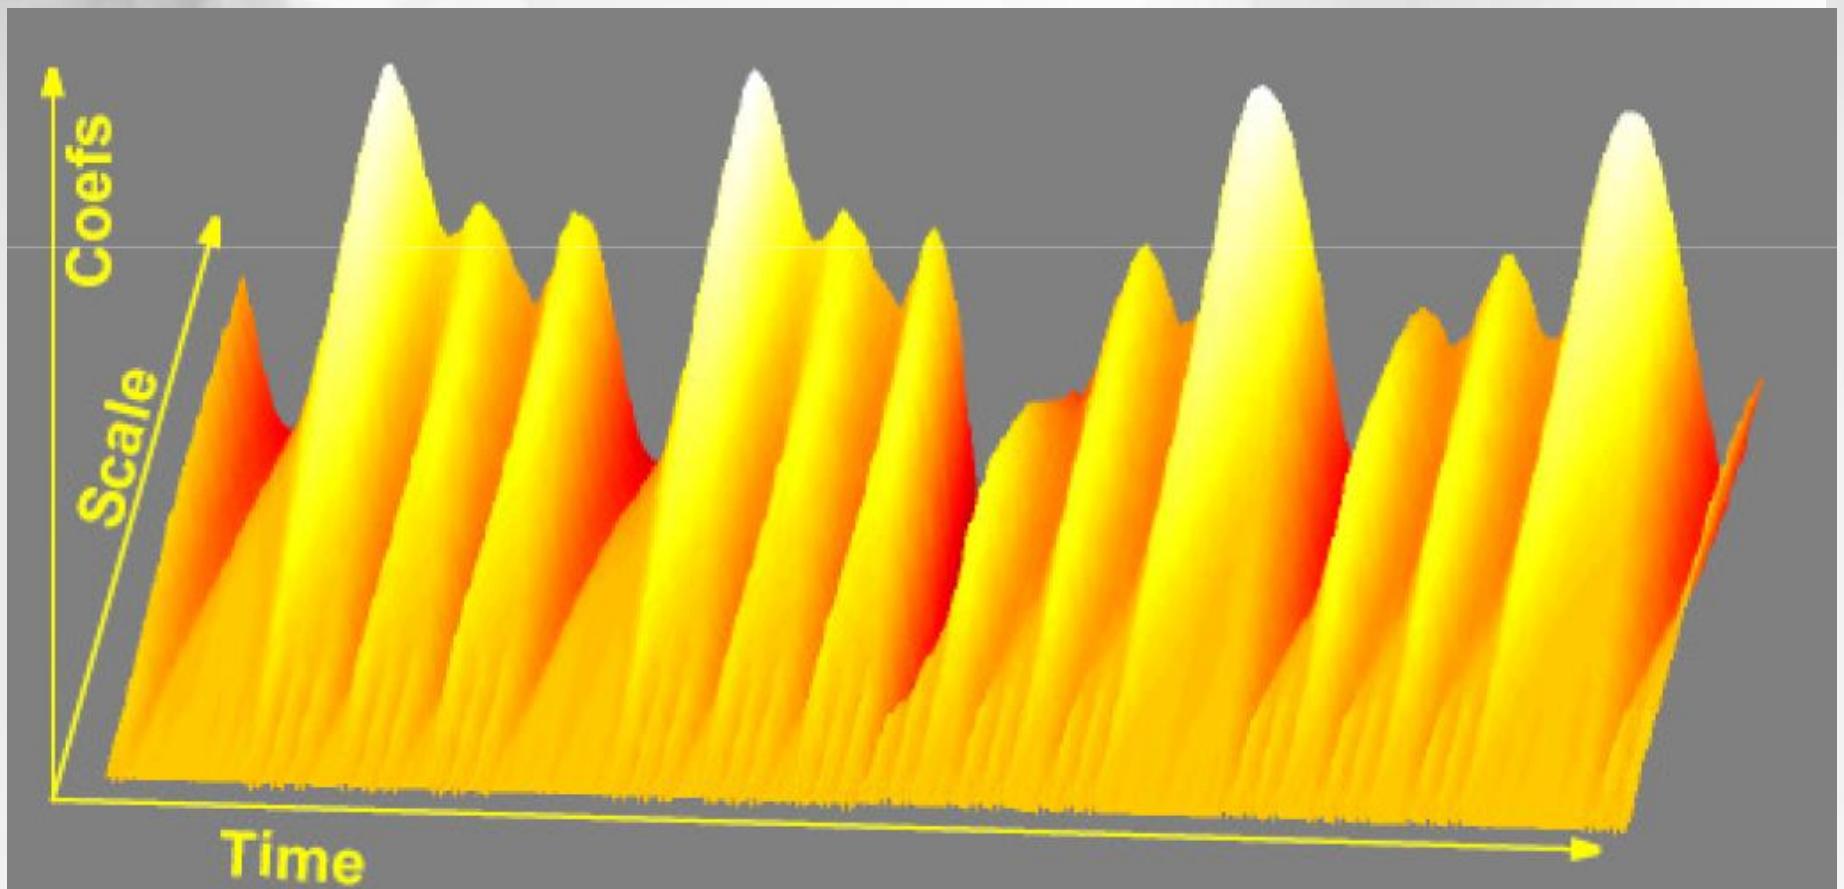
# Transformada Wavelet (cont.)

- Um gráfico é plotado em que  $x$  representa a posição ao longo do sinal (tempo),  $y$  representa a escala e a cor em cada ponto  $(x,y)$  representa a magnitude do coeficiente da *wavelet*.



# Transformada Wavelet (cont.)

- De uma visão em perspectiva teríamos:



# Funções wavelets mãe

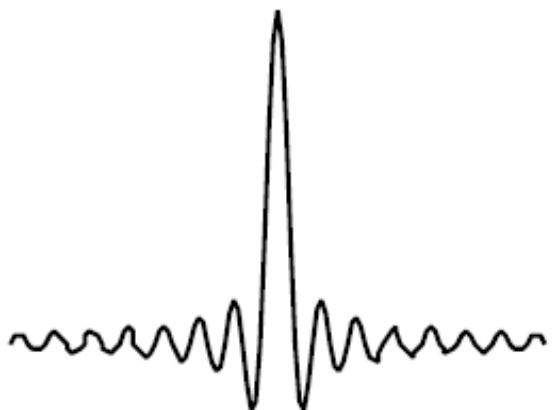
Ex. de funções que podem ser eleitas como wavelets mãe.

- 'haar' Haar wavelet.
- 'db' Daubechies wavelets.
- 'sym' Symlets.
- 'coif' Coiflets.
- 'bior' Biorthogonal wavelets.
- 'meyr' Meyer wavelet.
- 'gaus' Gaussian wavelets.
- 'mexh' Mexican hat wavelet.
- 'morl' Morlet wavelet.
- 'cgau' Complex Gaussian wavelets.
- 'fbsp' Frequency B-Spline wavelets.
- 'rbio' Reverse biorthogonal wavelets.
- 'dmey' Discrete approximation of Meyer wavelet.
- 'shan' Shannon wavelets.
- 'deO' de Oliveira wavelets.
- 'legd' Legendre wavelets.
- 'mth' Mathieu wavelets.
- 'cmor' Complex Morlet wavelets.

# Funções wavelets mãe (cont.)



Haar



Shannon or Sinc



Daubechies 2



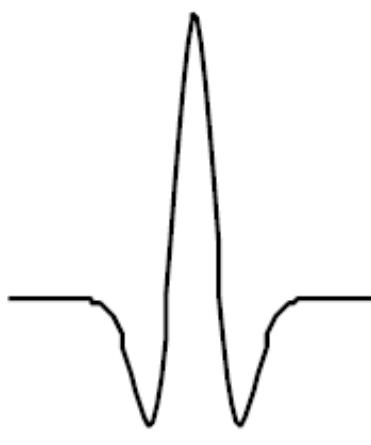
Daubechies 10



Gaussian or Spline



Biorthogonal



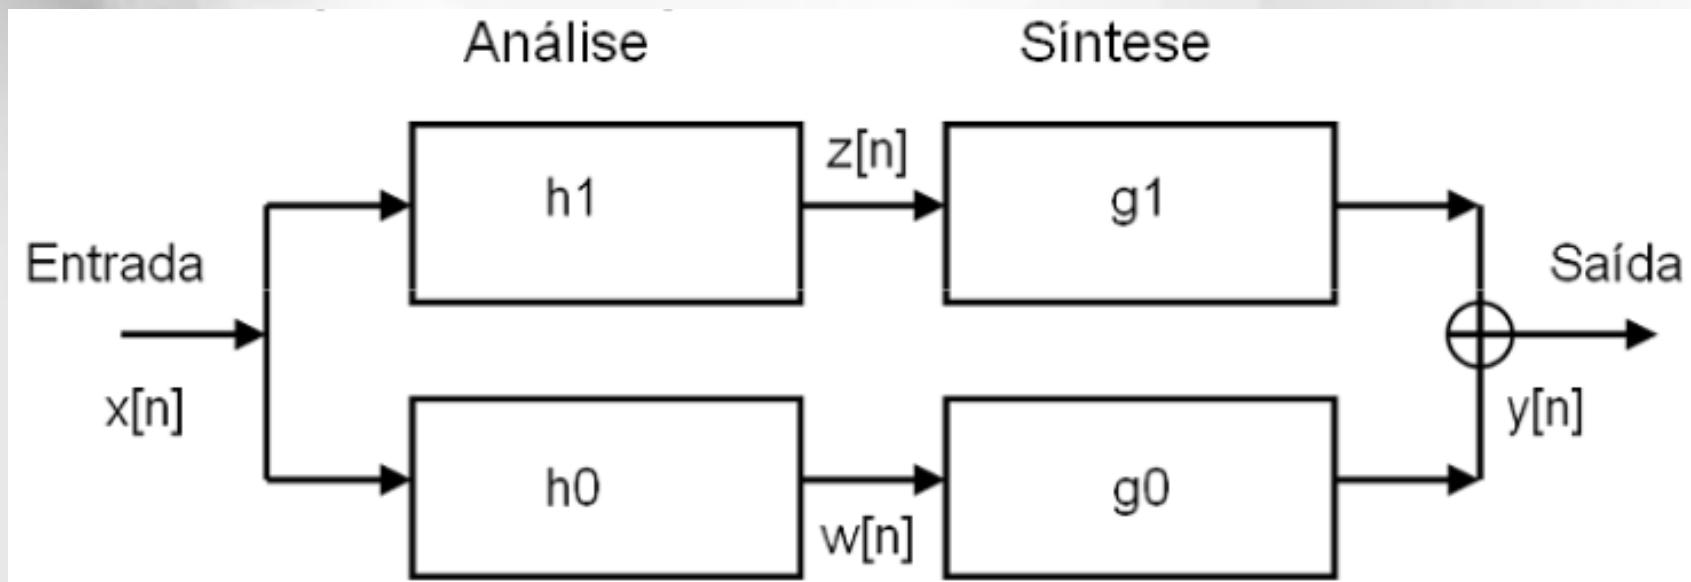
Mexican Hat



Coiflet

# Sobre os Coeficientes das wavelets

- Para demonstrar uma transformada geral, vamos usar o esquema apresentado abaixo:



- Nela, um sinal de entrada alimenta dois canais, cada qual com um par de filtro. Tal estrutura é chamada de **two-channel filter banks**.

# Sobre os Coeficientes das wavelets (cont.)

- A metade da esquerda da figura (filtros  $h_0$  e  $h_1$ ) corresponde à transformada direta

➤ Análise

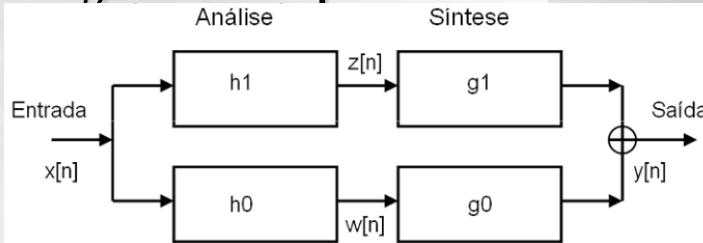
- A metade da direita é a transformada inversa

➤ Síntese

- É esperado que a síntese gere um sinal de saída igual ou muito próximo ao sinal de entrada.

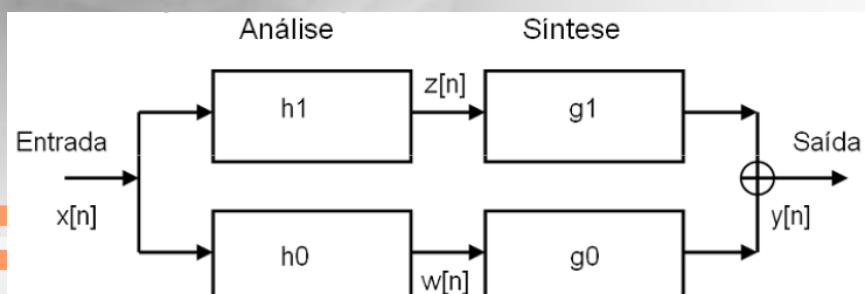
- Os filtros complementares de banco de filtros ( $h_0$  para  $h_1$ , e  $g_0$  para  $g_1$ ) dividem o sinal em sub-sinais de baixa e alta frequência

- Isso é chamado de *subband coding*.



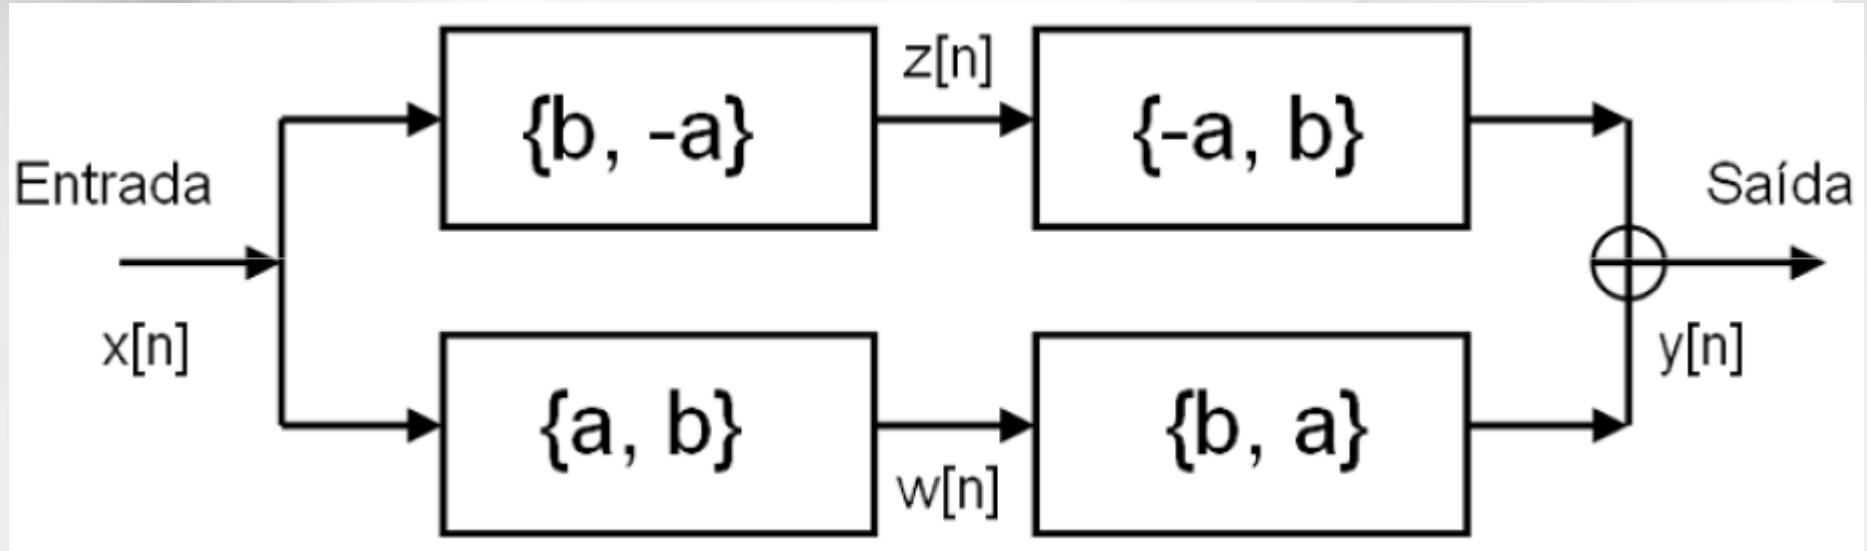
# Sobre os Coeficientes das wavelets (cont.)

- Para a transformada inversa, as saídas dos filtros da parte de análise ( $z[n]$  e  $w[n]$ ) passam por outros filtros e, em seguida, são combinadas para gerar a saída  $y[n]$ .
- A ideia é que  $w[n]$  e  $z[n]$  sejam versões transformadas de  $x[n]$  e que  $y[n]$  seja o sinal após a transformada inversa.
- Como dito anteriormente, espera-se que  $y[n]$  seja igual a  $x[n]$ .



# Sobre os Coeficientes das wavelets (cont.)

- 💡 Vamos considerar o *filter bank* da figura abaixo e vamos ver como se comportam  $w[n]$  e  $z[n]$ :

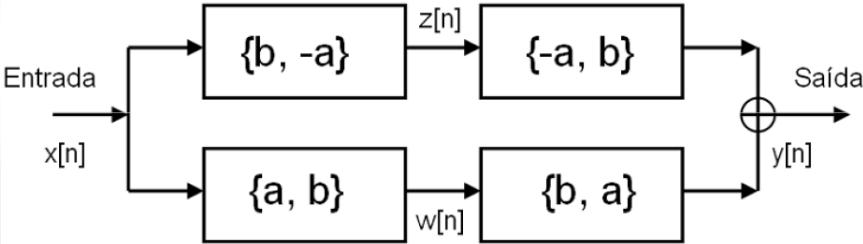


- 💡 Na parte da análise,  $w[n]$  e  $z[n]$  são definidos por:
  - $w[n] = a.x[n] + b.x[n - 1]$
  - $z[n] = b.x[n] - a.x[n - 1]$

# Sobre os Coeficientes das wavelets (cont.)

💡 Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$



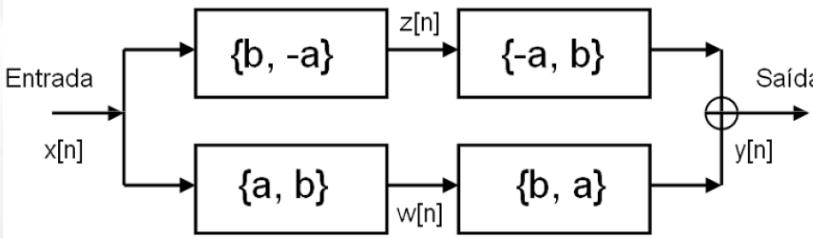
# Sobre os Coeficientes das wavelets (cont.)

💡 Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$

💡 Assim,  $y[n]$  será:

- $y[n] = -a.z[n] + b.z[n - 1] + b.w[n] + a.w[n - 1]$



# Sobre os Coeficientes das wavelets (cont.)

• Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

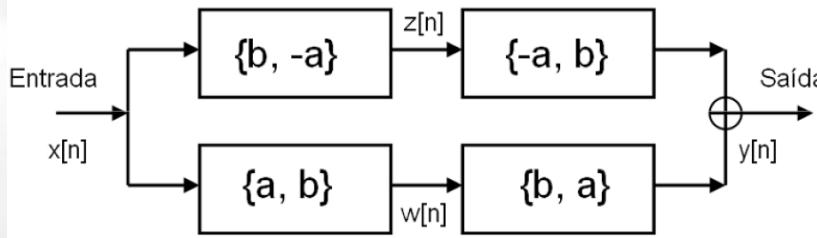
- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$

• Assim,  $y[n]$  será:

- $y[n] = -a.z[n] + b.z[n - 1] + b.w[n] + a.w[n - 1]$

• E, em relação ao sinal original:

- $y[n] = -a.(b.x[n] - a.x[n - 1]) + b.(b.x[n - 1] - a.x[n - 2]) + b.(a.x[n] + b.x[n - 1]) + a.(a.x[n - 1] + b.x[n - 2])$



# Sobre os Coeficientes das wavelets (cont.)

• Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

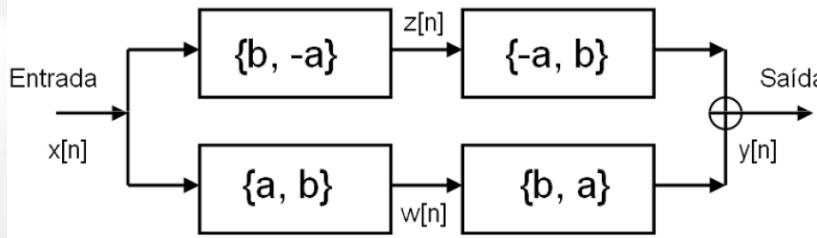
- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$

• Assim,  $y[n]$  será:

- $y[n] = -a.z[n] + b.z[n - 1] + b.w[n] + a.w[n - 1]$

• E, em relação ao sinal original:

- $y[n] = -a.(b.x[n] - a.x[n - 1]) + b.(b.x[n - 1] - a.x[n - 2]) + b.(a.x[n] + b.x[n - 1]) + a.(a.x[n - 1] + b.x[n - 2])$
- $y[n] = -a.b.x[n] + a.a.x[n - 1] + b.b.x[n - 1] - ba.x[n - 2] + b.a.x[n] + b.b.x[n - 1] + a.a.x[n - 1] + a.b.x[n - 2]$



# Sobre os Coeficientes das wavelets (cont.)

- Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

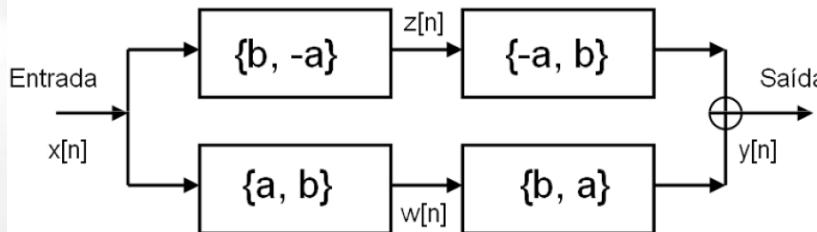
- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$

- Assim,  $y[n]$  será:

- $y[n] = -a.z[n] + b.z[n - 1] + b.w[n] + a.w[n - 1]$

- E, em relação ao sinal original:

- $y[n] = -a.(b.x[n] - a.x[n - 1]) + b.(b.x[n - 1] - a.x[n - 2]) + b.(a.x[n] + b.x[n - 1]) + a.(a.x[n - 1] + b.x[n - 2])$
- $y[n] = -a.b.x[n] + a.a.x[n - 1] + b.b.x[n - 1] - ba.x[n - 2] + b.a.x[n] + b.b.x[n - 1] + a.a.x[n - 1] + a.b.x[n - 2]$
- $y[n] = aa.x[n - 1] + bb.x[n - 1] + bb.x[n - 1] + aa.x[n - 1]$



# Sobre os Coeficientes das wavelets (cont.)

● Precisamos saber também quem são  $w[n - 1]$  e  $z[n - 1]$ :

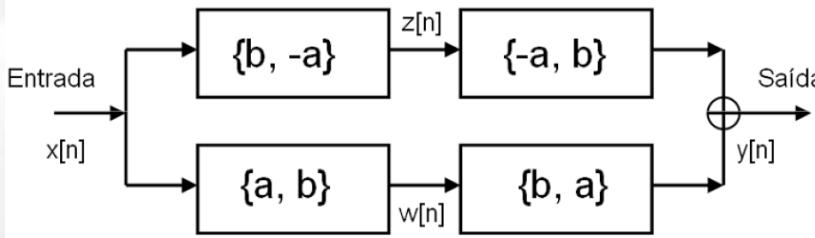
- $w[n - 1] = a.x[n - 1] + b.x[n - 2]$
- $z[n - 1] = b.x[n - 1] - a.x[n - 2]$

● Assim,  $y[n]$  será:

- $y[n] = -a.z[n] + b.z[n - 1] + b.w[n] + a.w[n - 1]$

● E, em relação ao sinal original:

- $y[n] = -a.(b.x[n] - a.x[n - 1]) + b.(b.x[n - 1] - a.x[n - 2]) + b.(a.x[n] + b.x[n - 1]) + a.(a.x[n - 1] + b.x[n - 2])$
- $y[n] = -a.b.x[n] + a.a.x[n - 1] + b.b.x[n - 1] - ba.x[n - 2] + b.a.x[n] + b.b.x[n - 1] + a.a.x[n - 1] + a.b.x[n - 2]$
- $y[n] = aa.x[n-1] + bb.x[n-1] + bb.x[n-1] + aa.x[n-1]$
- $y[n] = (2aa + 2bb).x[n-1]$



# Sobre os Coeficientes das wavelets *(cont.)*

- Essas operações retratam o processamento da wavelet de Haar.
- Essa é a mais simples das wavelets.
- Se escolhermos com cuidado os coeficientes, teremos a transformada de Haar.
- Por exemplo, se:

$$2aa + 2bb = 1$$

então

$$y[n] = x[n - 1]$$

ou seja, a saída é a entrada com um retardo de 1.

# Sobre os Coeficientes das wavelets (cont.)

- Se procurarmos  $a$  e  $b$  tal que:

$$aa + bb = 1$$

podemos ter  $aa = \frac{1}{2}$  e  $bb = \frac{1}{2}$

- Assim, se  $a = b = \frac{1}{\sqrt{2}}$ , teremos os coeficientes da transformada de Haar.

# Wavelet de Haar

- Wavelets correspondentes às bases caixas é dada por:

$$\psi_{j,k}(t) = 2^{\frac{j}{2}} \psi(2^j t - k)$$

sendo que a *wavelet* mãe é escalada no ponto (0,0) como:

$$\psi_{0,0}(t) = \begin{cases} 1 & \text{para } 0 \leq t < \frac{1}{2} \\ -1 & \text{para } \frac{1}{2} \leq t < 1 \\ 0 & \text{c.c.} \end{cases}$$

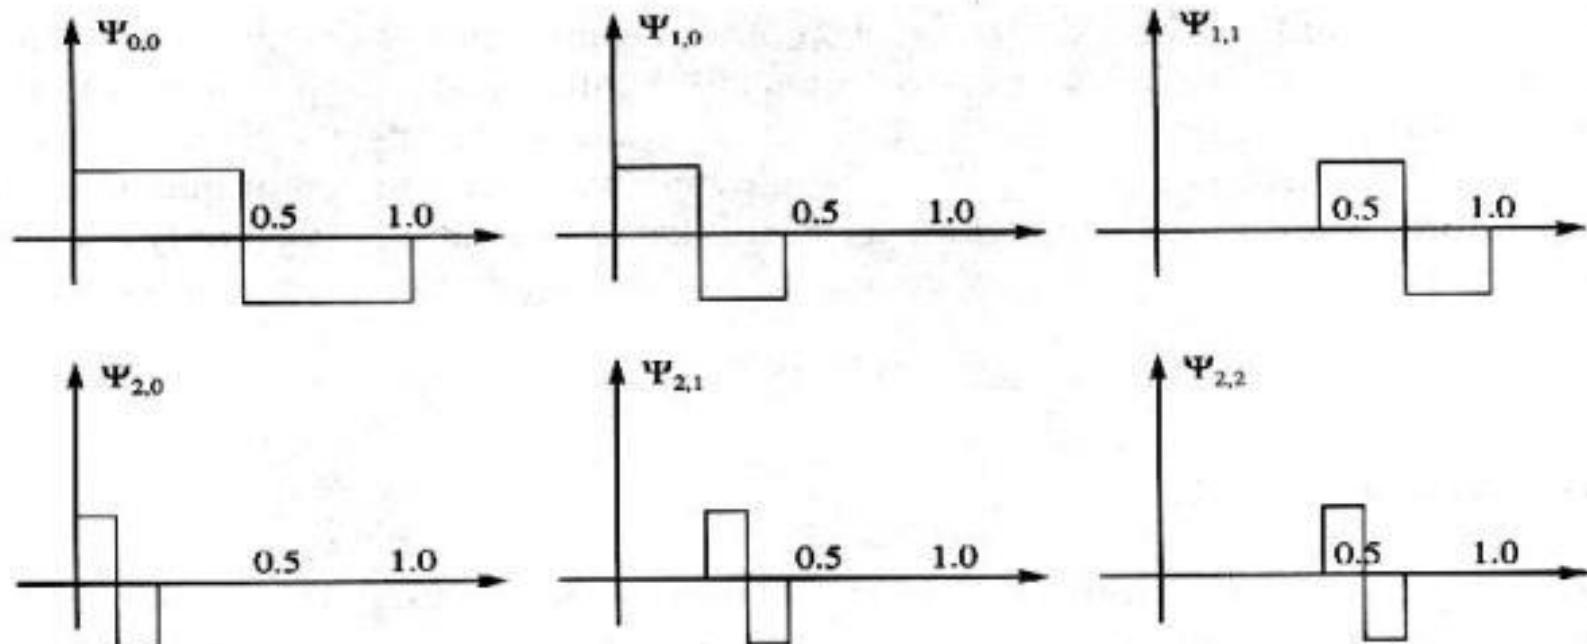
e suas *wavelets-filhas*, decompostas como:

$$\psi_{j,k}(t) = \psi_{0,0}(2^j t - k) = \begin{cases} 1 & \text{para } k2^{-j} \leq t < (k + \frac{1}{2})2^{-j} \\ -1 & \text{para } (k + \frac{1}{2})2^{-j} \leq t < (k + 1)2^{-j} \\ 0 & \text{c.c.} \end{cases}$$

# Wavelet de Haar

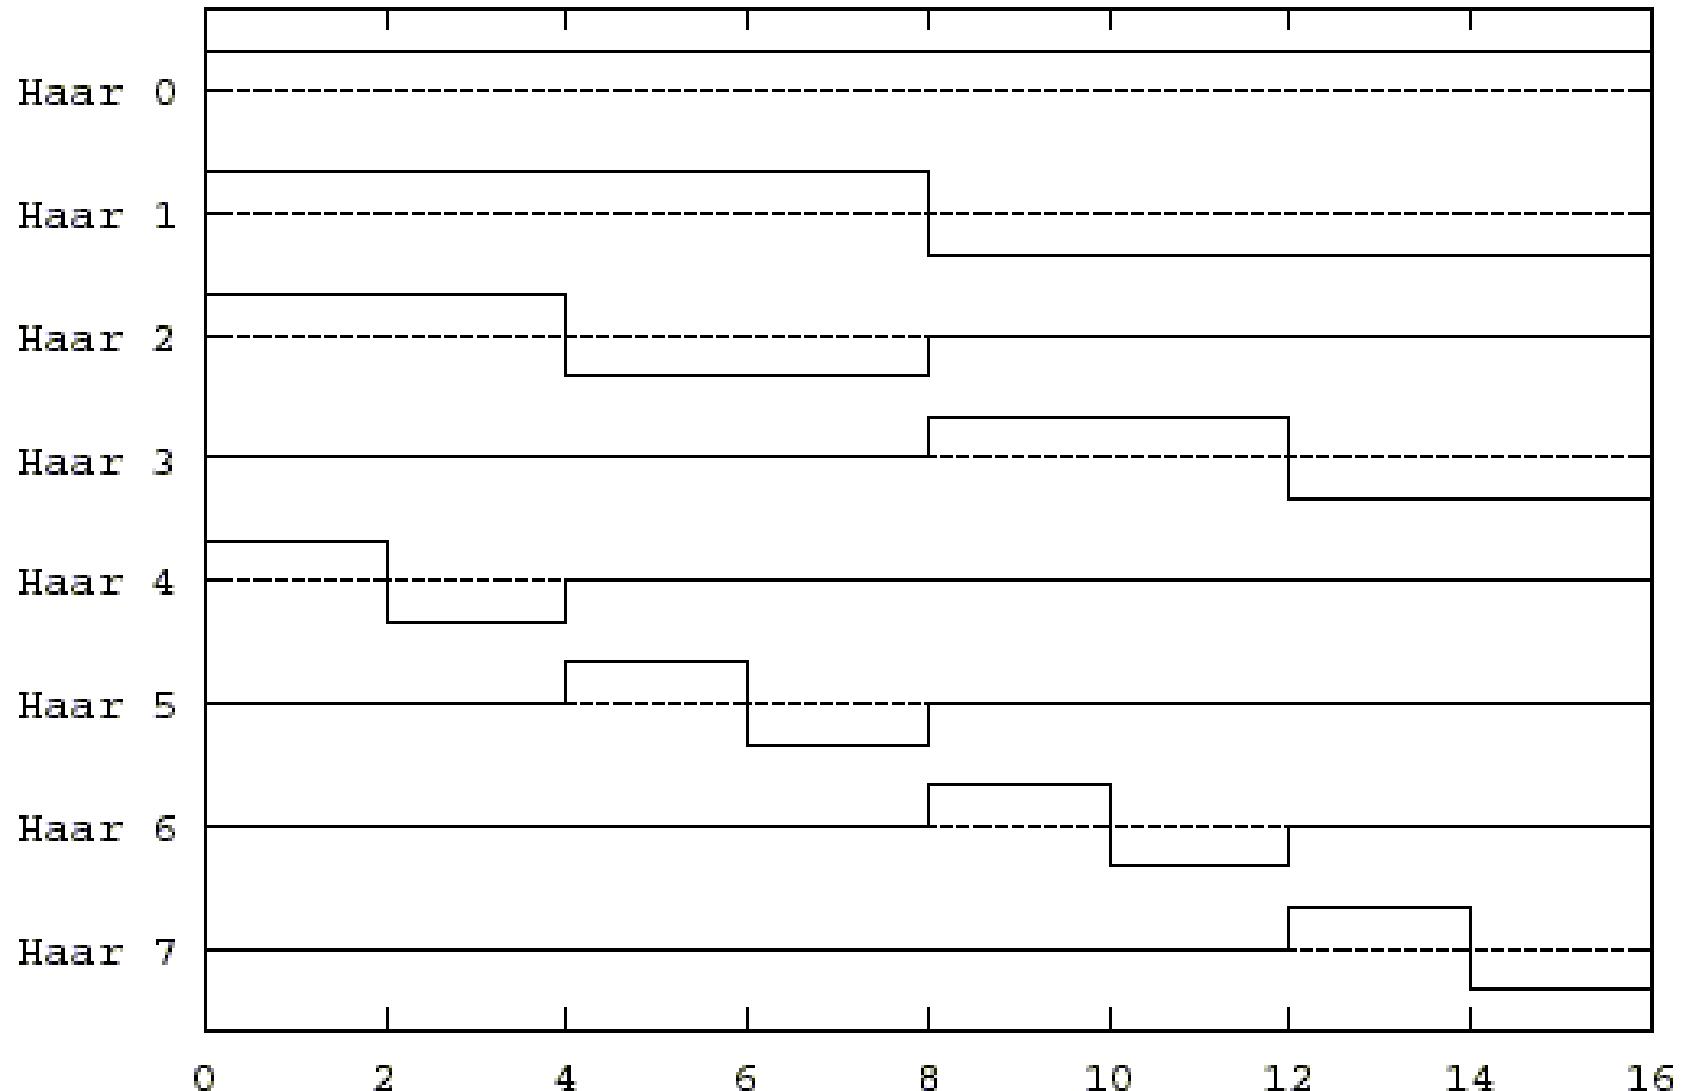
- Efeito dos índices: a figura abaixo mostra como ocorre a variação dos índices de escala e localização para a wavelet Haar.

$$Y_{j,k}(t) = Y_{0,0}(2^j t - k) = \begin{cases} 1 & \text{para } k2^j \leq t < (k + \frac{1}{2})2^j \\ -1 & \text{para } (k + \frac{1}{2})2^j \leq t < (k + 1)2^j \\ 0 & \text{c.c.} \end{cases}$$



- Índice  $j$  varia entre 1 e 2, apresentando a variação da largura da onda (efeito da escala), enquanto o índice  $k$  altera a posição da onda no eixo x (efeito de translação).

# Wavelet de Haar (cont.)



## Exemplo de Haar 1-D

- Sinal unidimensional:

7 5 2 8 9 5 3 3

- Faz-se um sinal com menor resolução pela aplicação de uma média par a par sobre o sinal anterior. Sinal resultante:

6 5 7 3

- Observa-se uma excessiva perda de informações nesta operação de média.

# Exemplo de Haar 1-D

- Essas informações perdidas são fundamentais para uma posterior recuperação do sinal original.
- Para essa recuperação faz-se necessário o armazenamento dos *coeficientes de detalhes* originários do processo de média.
  - Os *coeficientes* são obtidos armazenando-se os valores das diferenças entre o valor médio e os valores dos pixels envolvidos nesse cálculo.
  - Ex. para o 1º. par do exemplo anterior: 7 e 5 (média = 6).
  - $6 + 1 = 7$  e  $6 - 1 = 5$ .
    - ✓ Portanto o **coeficiente de detalhe** necessário para a recuperação dos dados originais (primeiro par) tem o valor 1.
  - Segundo par: 2 e 8 (média 5)
    - ✓ **Coeficiente de detalhe** (-3) pois  $5 + (-3) = 2$  e  $5 - (-3) = 8$ .

# Exemplo de Haar 1-D (cont.)

Resolução	Médias	Coeficientes de detalhes
8	7 5 2 8 9 5 3 3	
4	6 5 7 3	1 -3 2 0
2	5,5 5	0,5 2
1	5,25	0,25

Processo de decomposição por Wavelets em várias resoluções

- A Transformada Wavelet (decomposição Wavelet) do sinal 7 5 2 8 9 5 3 3 baseada na wavelet de Haar é dada pela sequência de números reais:

$$5.25 \quad 0.25 \quad 0.5 \quad 2 \quad 1 \quad -3 \quad 2 \quad 0.$$

- Aqui, para facilitar o entendimento, não consideramos a normalização da energia. Na aplicação da TW, ela deve ser considerado.

# Exemplo de Haar 1-D (cont.)

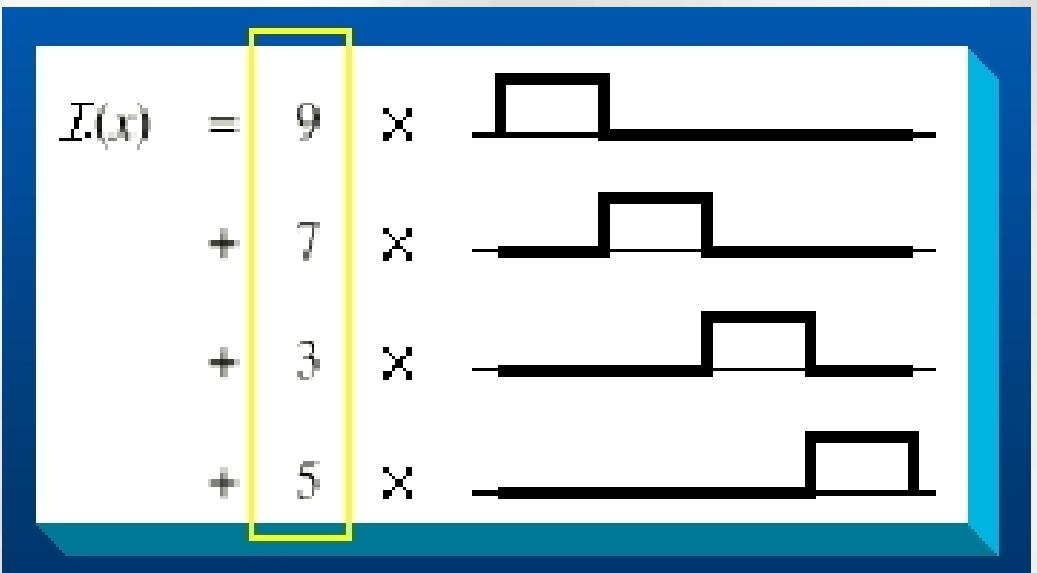
Uma representação mais gráfica para o vetor [9 7 3 5]:

Transf. Haar nível 1:  
cada linha na matriz  
representa um sinal na  
figura ao lado

$$\frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & 1 \\ 1 & -1 & 0 & 0 \\ 0 & 0 & 1 & -1 \end{pmatrix} \begin{pmatrix} 9 \\ 7 \\ 3 \\ 5 \end{pmatrix} = \sqrt{2} \begin{pmatrix} 8 \\ 4 \\ 1 \\ -1 \end{pmatrix}$$

Médias ponderadas (tendência do sinal)

Flutuações do sinal



## Exemplo de Haar 1-D (cont.)

🟡 Nível 2:

$$\frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ 1 & -1 \end{pmatrix} \sqrt{2} \begin{pmatrix} 8 \\ 4 \end{pmatrix} = 2 \begin{pmatrix} 6 \\ 2 \end{pmatrix}$$

🟡 Assim, a TW final para Haar 1-D ficará

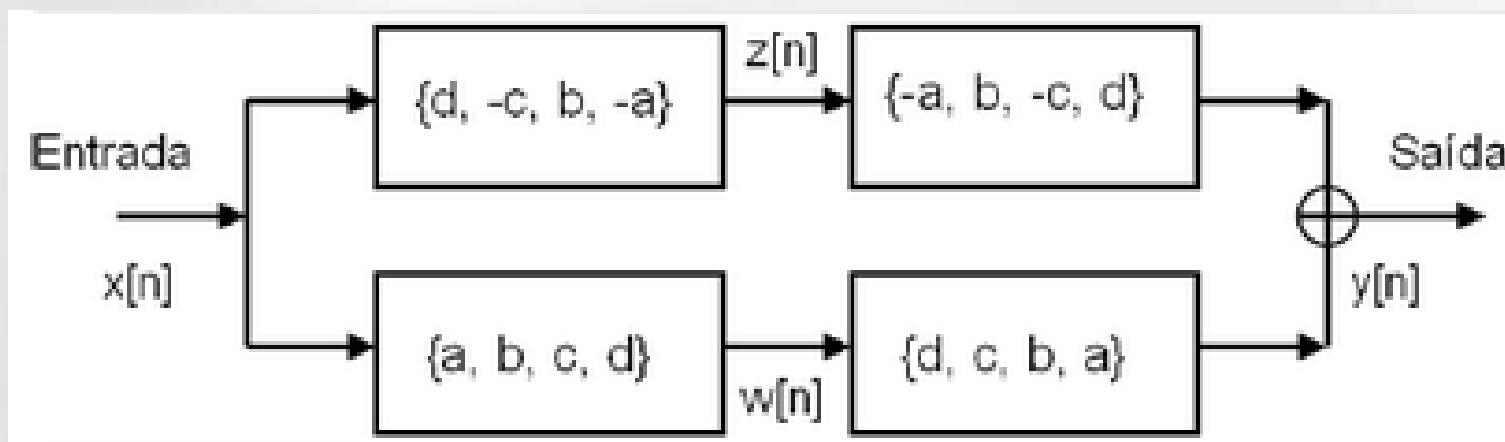
$$[6*2 \quad 2*2 \quad 1*\sqrt{2} \quad -1*\sqrt{2}] = [12 \quad 4 \quad \sqrt{2} \quad -\sqrt{2}]$$

# Implementando Wavelet Haar Multiresolução

- O procedimento descrito anteriormente para transformada Haar de nível 1 pode ser repetido múltiplas vezes.
- Aplica-se recursivamente a transformada ao sinal resultante da transformada anterior para obter transformadas em níveis maiores.
- As flutuações não devem ser alteradas e continuam a dividir a média ponderada apenas.

# Exercício

💡 Faça o processamento de um sinal usando uma *wavelet* de 4 coeficientes e o filtro conforme mostrado na figura abaixo. Considere que  $a.c = -b.d$



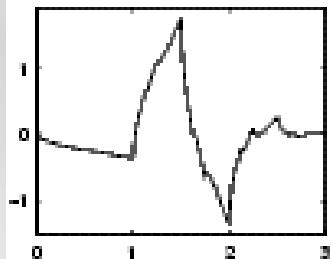
# Wavelet de Daubechies

- Wavelets de Haar são de suporte compacto, porém não são diferenciáveis (não apresentam suavidade).
- Um dos maiores desafios da teoria de wavelets foi a construção de uma família de wavelets de suporte compacto.
- Um das famílias de wavelets mais utilizadas é a família das *Daubechies*.
- Criada por Ingrid Daubechies, a família das wavelets Daubechies (ou db) é a única família de wavelets que tem suporte compacto e decaimento suave.
  - Suporte compacto impede que a wavelet se espalhe por todo o espectro.
  - Decaimento suave impede que a wavelet introduza artefatos de altas frequências.

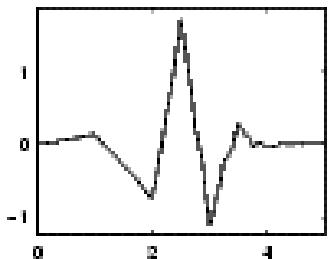
# Wavelet de Daubechies

- A regularidade das wavelets de Daubechies aumenta linearmente com N, porém a preço de aumentar o comprimento do suporte.
- Família Daubechies - várias *wavelets* diferentes; Não existe uma expressão explícita para defini-las, exceto para a primeira (DB1) que é a *wavelet* de Haar.

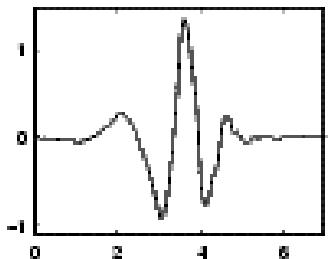
# Wavelet de Daubechies (cont.)



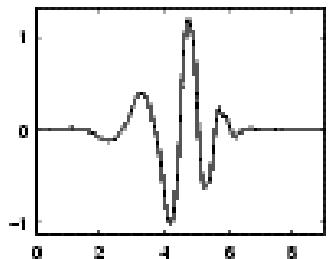
db2



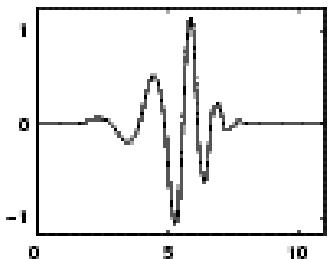
db3



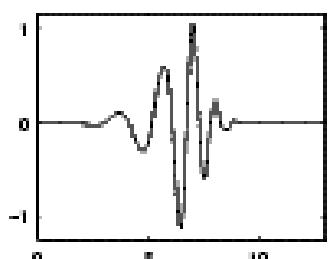
db4



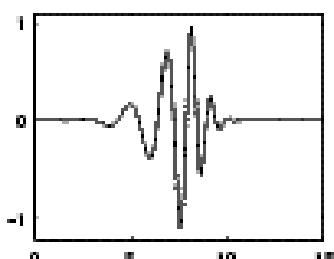
db5



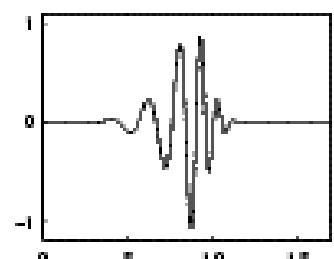
db6



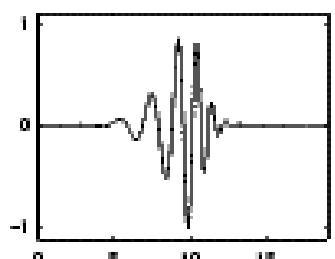
db7



db8



db9



db10

- Interessante observar que a wavelet-mãe db2 exibe um formato característico de "cauda de tubarão".

# Wavelet de Daubechies (cont.)

- ➊ São utilizadas duas *wavelets*:  $\phi(x)$  e  $\psi(x)$ , denominadas, respectivamente de *wavelets* pai e *wavelet* mãe.
- ➋ As *wavelets* mãe são utilizadas para determinar os detalhes de um sinal e a informação de tendência é armazenada nos coeficientes obtidos pelas *wavelets* pai.

# Wavelet de Daubechies (cont.)

- A análise de multiresolução da tendência e flutuação de uma função é implementada mediante sua convolução com um filtro passa-baixa e um filtro passa-alta.
- As TW de Daubechies preservam mais a informação de tendência nos sinais quando considerados apenas a parte do filtro passa-baixa.

# Wavelet de Daubechies (cont.)

💡 Exemplo de *wavelet* de Daubechies-4:

$$\left\{ \frac{\sqrt{3}+1}{4\sqrt{2}}, \frac{3+\sqrt{3}}{4\sqrt{2}}, \frac{3-\sqrt{3}}{4\sqrt{2}}, \frac{1-\sqrt{3}}{4\sqrt{2}} \right\}$$

→ filtro passa-baixa

$$\left\{ \frac{1-\sqrt{3}}{4\sqrt{2}}, \frac{-\sqrt{3}-3}{4\sqrt{2}}, \frac{3+\sqrt{3}}{4\sqrt{2}}, \frac{-1-\sqrt{3}}{4\sqrt{2}} \right\}$$

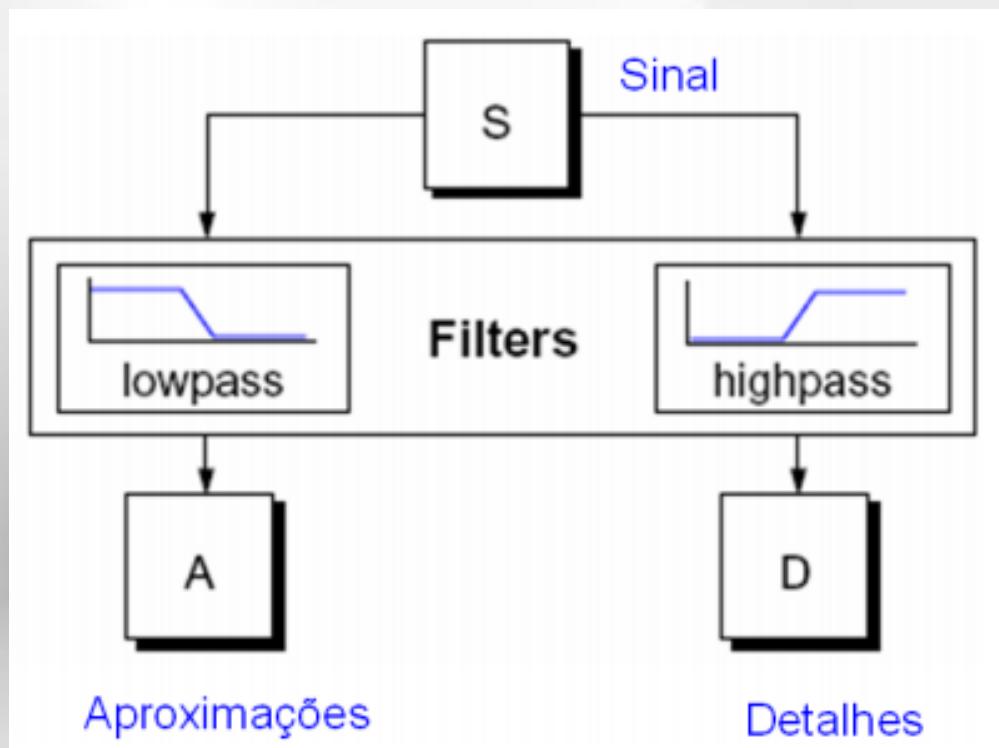
→ filtro passa-alta

# Análise em Multiresolução

- A intenção inicial da transformada *wavelet* é poder observar um sinal em suas diferentes frequências.
- Na maioria dos casos, as informações de baixa frequência são as mais importantes.
- Sendo assim, um sinal pode ser dividido em duas partes:
  - Aproximações: componentes de alta escala e baixa frequência do sinal.
  - Detalhes: componentes de pequena escala e alta frequência do sinal.

# Análise em Multiresolução (cont.)

- Esta divisão nada mais é do que a divisão de um sinal em baixas e altas frequências, o que pode ser facilmente conseguido com o uso de filtros passa-baixa e passa-alta.



# Fontes

## Slides

- Prof. Hélio Magalhães de Oliveira – UFPE
- Prof. Carlos Alexandre Mello – UFPE

## Referências

- de Oliveira, H. M. *Wavelets – Entrando na Onda*, Universidade Federal de Pernambuco, Recife – PE, 2002.
- Van Dorngelen, W. *Signal Processing for Neuroscientists*, Elsevier, 2007.